

T.C.
ESKİŞEHİR OSMANGAZİ ÜNİVERSİTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ
2023-2024 Eğitim-Öğretim Yılı

152118508 - ENGINEERING RESEARCH ON
DATABASE APPLICATIONS
FİNAL RAPORU

Proje Başlığı

Derin Öğrenme ile Diyabetik Retinopati Hastalığının Sınıflandırılması

Projeyi Hazırlayanlar:

Avni Faruk Muratoğlu 152120191010 Bilgisayar Mühendisliği

Göknur Sevinç 152120191013 Bilgisayar Mühendisliği

Şevval Kolaca 152120191019 Bilgisayar Mühendisliği

Sinan Kompas 152120191070 Bilgisayar Mühendisliği

Danışman:

Dr. Öğr. Üyesi Yıldırım Anagün

Temmuz 2024

A. PLANLAMA	4
A.1. ÖZET VE ANAHTAR KELİMELER	4
A.2. BİLGİ, GEREKSİNİM BELİRLEME, PROBLEMİN TANIMLANMASI	5
A.2.1. Amaç	5
A.2.2. Konu, Kapsam	5
A.2.3. Literatür Özeti	5
A.3. BEKLENEN FAYDA	9
A.3.1. Özgün Değer	9
A.3.2. Yaygın Etki, Katma Değer	9
A.4. YÖNTEM	9
A.4.1. Veri Seti	9
A.4.2. Veri Ön İşleme ve Model Oluşturma	11
A.4.3. Web Uygulaması	11
A.5. ARAŞTIRMA OLANAKLARI	12
A.6. ÇALIŞMA TAKVİMİ	13
A.6.1. İş Zaman Çizelgesi	13
A.6.2. Kişi İş Açıklaması	14
B. ANALİZ	15
B.1. SİSTEM GEREKSİNİMLERİNİ ORTAYA ÇIKARMA YÖNTEM VE TEKNİKLERİ	15
B.1.1. Yüz Yüze Görüşme	15
B.1.2. Yazılı Basılı Belge İnceleme	15
B.1.3. Anket	15
B.1.4. Gözlem	18
B.1.5. Prototip ve Hızlı Uygulama Tasarım (Rapid Application Design- RAD)	18
B.1.6. Ortak Uygulama Tasarım (Joint Application Design-JAD)	19
B.1.7.2 Mantıksal Veri Akış Şeması	20
B.1.7.3 Fiziksel Veri Akış Şeması	21
B.1.7.4 İş Akış Şeması	22
B.1.8. Olay Tabloları, Durum Formları, İşlevsel Analiz Raporu	25
B1.8.1 Olay Tabloları	25
B.1.8.2 Durum Formları	25
B.1.8.3. İşlevsel Analiz Raporu	27
B.2. SİSTEM GEREKSİNİMLERİ	27
B.2.1. İşlevsel Gereksinimler	27
B.2.2. Sistem ve Kullanıcı Arayüzleri ile İlgili Gereksinimler	27
B.2.3. Veriyle İlgili Gereksinimler	28
B.2.4. Kullanıcılar ve İnsan Faktörü Gereksinimleri, Güvenlik Gereksinimleri	28
B.2.5. Teknik ve Kaynak Gereksinimleri, Fiziksel Gereksinimler	28
C.TASARIM	28
C.1. SİSTEM TASARIMI	28
C.2.KULLANICI VE SİSTEM ARAYÜZÜ TASARIMLARI	29
C.3. TEST TASARIM	31
C.3.1 Gereksinim Analizlerinden Teste Yönelik Hedeflerin Detaylandırılması	31
C.3.2. Fonksiyonel Test Tasarımı	32
C.3.2.1. Birim (Unit) Testleri Tasarımı	32
C.3.2.2. Entegrasyon Testleri Tasarımı	32
C.3.3. Performans Test Tasarımı	33
C.4.YAZILIM TASARIMI	34
C.4.1. Gereksinime Bağlı Yazılım Kalıpları Seçimi	34
C.4.2. UML Kullanarak Tasarım Diyagramı Oluşturma	34
C.5. VERİ TABANI TASARIMI	35
C.5.1. Veri Tabanı İsterler Dokümanı	35
C.5.2. E/R Diyagramı	36
C.5.3. Stored Procedures, Triggers, Kısıtların Tasarımı	36
C.6. DONANIM TASARIMI	36

D.UYGULAMA	36
D.1 GELİŞTİRİLEN SİSTEMİN SİSTEM TASARIMLARINI KARŞILANMASININ DEĞERLENDİRİLMESİ	37
D.2. KULLANICI VE SİSTEM ARAYÜZÜ GERÇEKLEMELERİ.....	37
D.3.GERÇEKLEŞEN TESTLER	42
<i>D.3.1.Fonksiyonel Testler</i>	42
D.3.1.1. Birim (Unit) Testi	42
D.3.1.2. Entegrasyon Testi	43
<i>D.3.2. Performans Testi</i>	44
D.4. YAZILIM/VERİ TABANI/DONANIM GERÇEK.....	44
<i>D.4.1. Yazılım Gerçeklemeleri</i>	44
D.4.1.1. Diyabetik Retinopati Derecelendirme Modeli Gerçeklemeleri	44
D.4.1.2 Web Uygulaması Gerçeklemesi.....	46
<i>D.4.2. Veri Tabanı Gerçeklemeleri</i>	46
<i>D.4.3. Donanım Gerçeklemeleri</i>	46
E. SONUÇ VE ÖNERİLER	46
F. REFERANSLAR	48
E. DEĞERLENDİRME ŞABLONU	51

A. PLANLAMA

A.1. Özet ve Anahtar Kelimeler

ÖZET

Diyabetik retinopati, diyabet hastalarında sıkça görülen ve görme kaybının önde gelen nedenlerinden biridir. Diyabetin yüksek kan şekeri seviyelerine neden olmasıyla retinanın hasar görmesi sonucunda ortaya çıkmaktadır. Özellikle tip 1 veya tip 2 diyabeti olan her bireyde diyabetik retinopati görülebilir. Diyabet süresi uzadıkça, diyabetik retinopati görülme riski de artmaktadır.

Bu çalışmanın amacı, diyabetik retinopati hastalığının sınıflandırılmasının daha hızlı ve güvenilir sonuçlar elde etmesine yardımcı olacak bir web uygulaması geliştirmektir. Derin öğrenme yöntemlerini kullanarak, göz dokularının detaylı görüntülerini analiz ederek hastalığın hangi evrede olduğunu tespit etme hedeflenmektedir. Bu şekilde, doktorlara ve hastalara hastalığın yönetimi konusunda önemli bir araç sağlanması amaçlanmaktadır. Çalışmamızda Kaggle platformunda paylaşılan bir veri seti ve EfficientNetV2S, EfficientNetV2B0 ve ResNet18 sinir ağları kullanılmaktadır.

Web sayfası üzerinde, doktorlar hastanın göz görüntülerini yükleyebilecek ve sistemimiz tarafından yapılan otomatik derecelendirme sonuçlarını alabileceklerdir. Bu sayede, sağlık profesyonelleri hastaların göz görüntülerini hızlı bir şekilde analiz edebilir ve diyabetik retinopatinin evresini belirleyebilirler. Bu web tabanlı uygulama, doktorların iş yükünü azaltarak daha verimli bir çalışma ortamı sağlayacak ve hastaların erken teşhis ve tedaviye erişimini artıracaktır.

Anahtar Kelimeler: Derin Öğrenme, Konvolüsyonel Sinir Ağları, Diyabetik Retinopati Hastalığının Sınıflandırılması

ABSTRACT

Diabetic retinopathy is a common and leading cause of vision loss in diabetic patients. It occurs as a result of damage to the retina caused by diabetes causing high blood sugar levels. Diabetic retinopathy can be seen in any individual, especially with type 1 or type 2 diabetes. As the duration of diabetes increases, the risk of diabetic retinopathy also increases.

The aim of this study is to develop a web application that will help classify diabetic retinopathy disease to obtain faster and more reliable results. It is aimed to determine the stage of the disease by analyzing detailed images of eye tissues using deep learning methods. In this way, it is aimed to provide doctors and patients with an important tool in the management of the disease. In our study, a dataset shared on the Kaggle platform and EfficientNetV2S, EfficientNetV2B0 and ResNet18 neural networks are used.

On the web page, doctors will be able to upload patient eye images and receive automatic rating results made by our system. In this way, healthcare professionals can quickly analyze patients' eye images and determine the stage of diabetic retinopathy. This web-based application will provide a more efficient working environment by reducing doctors' workload and increase patients' access to early diagnosis and treatment.

Keywords: Deep Learning, Convolutional Neural Networks, Classification of Diabetic Retinopathy Disease

A.2. Bilgi, Gereksinim Belirleme, Problemin Tanımlanması

A.2.1. Amaç

Günümüzde, teknolojinin hızlı gelişimi sağlık sektöründe de önemli bir dönüşüme yol açmaktadır. Yapay zeka, derin öğrenme ve makine öğrenmesi gibi teknolojiler, tıp alanında tanı ve tedavi süreçlerinde daha hızlı, doğru ve objektif sonuçlar elde etmeyi mümkün kılmaktadır. Bu teknolojilerin tıbbi görüntüleme alanında kullanılması, hastalıkların erken teşhisi ve tedavisi için büyük potansiyel sunmaktadır. Bu bağlamda, bu çalışmanın amacı, diyabetik retinopati tanısında daha hızlı bir yaklaşımın geliştirilmesidir. Diyabetik retinopati, görme kaybının önde gelen nedenlerinden biri olup, diyabet hastalarının yaşam kalitesini ciddi şekilde etkileyebilmektedir.

Bu çalışmada, göz dokularının detaylı görüntülerinin analizi için EfficientNetV2S, EfficientNetV2B0 ve ResNet18 derin öğrenme modelleri kullanılarak diyabetik retinopati tanısı yapılacaktır. En yüksek doğruluk sonucunu alacağımız Kaggle platformunda paylaşılan bir veri seti üzerinde yapılan çalışma, sağlık profesyonellerine hastalığın evresini belirlemede yardımcı olacak objektif bir araç sağlamayı hedeflemektedir. Bu sayede, hastaların erken teşhis edilerek uygun tedaviye erişimi artırılarak görme kaybının önlenmesine katkıda bulunulması amaçlanmaktadır.

A.2.2. Konu, Kapsam

Bu projenin sağlık sektörü kapsamında geliştirilmesi, özellikle göz doktorlarına yardımcı olması amaçlanmaktadır. Diyabet hastalarında sıkça görülen ve görme kaybına neden olan Diyabetik Retinopati hastalığını derecelendirilmesini sağlayan bir model geliştirilmektedir. Bu modelin eğitim ve test aşamalarında, Kaggle platformundan temin edilen ve EyePacs tarafından sağlanan sağ ve sol retina görüntülerini içeren bir veri seti kullanılacaktır [1].

Diyabetik Retinopati hastalığının tespitinde, hastanın hastalığa sahip olup olmadığını belirlemek için beşli bir sınıflandırma modeli oluşturulacaktır: hastalık yok, hafif non- proliferatif diyabetik retinopati, orta non-proliferatif diyabetik retinopati, şiddetli non-proliferatif diyabetik retinopati, proliferatif diyabetik retinopati.

A.2.3. Literatür Özeti

Son yıllarda Diyabetik Retinopati hastalığının tespit ve sınıflandırmasında, Konvolüsyonel Sinir Ağları (CNN) gibi Derin Öğrenme (DÖ) yaklaşımlarından birçok aktif çalışma yapılmıştır. Bu alandaki çalışmalardan biri, Asya Pasifik Tele-Oftalmoloji Derneği (APTOS) Sempozyumu'nda sunulan bir çalışmadır [2]. Bu çalışmada, görüntü boyutlarını dengeleme, ışıklandırma ayarı, clache, augmentation gibi ön işlemler uygulanmıştır. Çalışmada DenseNet121, ResNet50, ResNet101, EfficientNet-b4 gibi sınıflandırıcı modeller kullanılmıştır ve doğruluk değerleri sırasıyla %68, %66.80, %68, %74.40 olarak elde edilmiştir. Benzer şekilde, [3] içerisinde DRD, IDRiD, DDR veri setleri kullanılmış ve fundus görüntüler üzerinde çeşitli ön işlemler gerçekleştirilmiştir. Bu ön işlemler arasında görüntü kırpma, boyutlandırma, normalizasyon ve görüntü iyileştirme algoritmaları bulunmaktadır. Sınıflandırma için ise Inception V3, Resnet152, Inception, Resnet-V2 gibi modeller kullanılmıştır ve bu çalışmada kullanılan Adam optimizier ile %87.91, %87.20, %86.18 doğruluk sonuçları elde edilmiştir.

Sınıflandırma, nesne tespiti ve segmentasyon yöntemlerini içeren başka bir çalışmada, yeniden boyutlandırma, sıkıştırma, veri temizleme, tropikamid genişletme, merkez belirleme ön işleme adımları

gerçekleştirilmiştir [4]. VGG16, VGG19, ResNet50, ResNet101, ResNet152, Inception v3, ResNet50 v2, ResNet101 v2, ResNet152 v2, Xception, InceptionResNet v2, MobileNet v2, DenseNet169, DenseNet201, EfficientNetB0 gibi çoklu sınıflandırıcı modelleri kullanılmıştır. Aralarında en yüksek doğruluk oranına sahip modelin %64.99 ile VGG19 olduğu gözlemlenmiştir. Diğer modellerin %54.70-%63.84 arasında başarı oranlarının daha düşük olduğu gözlemlenmiştir.

Stack modeli (Resnet50, Inceptionv3, Xception, Dense-121, Dense169) üzerinden yapılan bir diğer çalışma [5] tarafından gerçekleştirilmiştir. Önerdikleri yönetimde Adam optimizier parametresine farklı değerler verilerek (0.01-0.001-0.0001-1.00E-05) sonuç elde etmişlerdir. Yeniden boyutlandırma, upsampling ve downsampling, normalizasyon ön işleme adımları gerçekleştirerek elde edilen sonuçlarda doğruluk değerlerinin 0.01-0.001-0.0001-1.00E-05 için sırasıyla %15, %50, %55, %70 olduğu görülmüştür. EyePacs veri seti kullanarak yapılan başka bir çalışmada [6] ise, veri artırma yöntemleri kullanılarak başarı oranının yükselmesi sağlanmıştır. VGG-16 sınıflandırıcı modeli için doğruluk oranı %89.20 çıkmıştır.

Convolutional Neural Networks (CNN), LDA (Linear Discriminant Analysis), KNN (K- Nearest Neighbor), SVM (Support Vector Machine), DT (Decision Tree), ANN (Artificial Neural Network) gibi birden fazla derin öğrenme ve makine öğrenmesi yöntemi [7] çalışması içerisinde kullanılmıştır. Bununla birlikte, DRIVE (Digital Retinal Images for Vessel Extraction) veri seti kullanılan çalışmada Yeşil Kanal Seçimi, CLAHE, Gürültü Azaltma, Vasküler Yapı İyileştirme, Görüntü Standardizasyonu preprocess adımları uygulanmıştır. Her bir derin öğrenme yöntemi için sırasıyla %78.5, LDA %94.7, KNN %93.7, SVM %95.1, DT %98, ANN %98.7 sonuçlarını elde etmişlerdir.

Kaggle' da 35000' den fazla görüntü içeren veri seti kullanılan bir modelde [8] her bir görüntünün giriş boyutu 512 x 512 olarak alınmıştır. ResNet-50 sınıflandırıcı modeli kullanılan çalışmada Adam optimizier uygulanmıştır. Model, %89.4 doğruluk oranı elde etmiştir. Birden fazla veri seti (Messidor-2, STARE, DRIVE, DIARETDB, EYEPACS, KAGGLE) ve birden fazla sınıflandırıcı model (CNN, DNN, Ensemble CNN, DCNN) kullanılan başka bir çalışma [9] gerçekleştirilmiştir. Yine birçok optimizier algoritmaları (Adaboost algorithm, batch normalization, ReLU) kullanılmıştır. İlgilenilen bölgenin çıkarılması, gürültünün giderilmesi gibi preprocess adımları uygulanmıştır. Doğruluk oranı en yüksek %98.7 elde edilmiştir.

207130 görüntü içeren bir veri seti Kaggle'dan edinilmiş ve CNV, DME, DRUSEN ve NORMAL olmak üzere dört sınıf içeren bir model [10] üzerine çalışılmıştır. Bu çalışmada, Inception-v4 sinir ağı modeli ve SGD optimizier kullanılarak %97.7 doğruluk elde edilmiştir. Asya Pasifik Tele-Oftalmoloji Derneği (APTOS) Sempozyumu'nda yayınlanan başka bir çalışmada [11], yeşil kanal, CLAHE, morfolojik yakınlık ve background exclusion preprocess adımları kullanılmış ve bir CNN tekniği kullanılmıştır. Bu çalışma sonucunda %95.35 doğruluk sonucu açıklanmıştır.

Bahsedilen araştırmalarımızın yanı sıra, daha geniş kapsamlı bir literatür taraması yapılarak derlenen bilgilere göre ayrıca bir tablo oluşturduk. İlgili tablo şu şekildedir:

Yöntem	Kullanılan Veri Seti	Preprocess Adımları	Sınıflandırıcı Model	Performans
[3]	Hastane ortaklığında oluşturulmuş veri seti.	- Fundus görüntü çerçevesinde crop işlemi, resized 520x520, normalizasyon, görüntü iyileştirme algoritması	Inception V3, Resnet152, Inception-Resnet-V2	Inception V3 = Acc: %87,91 Resnet152 = Acc: %87,20 Inception-Resnet-V2 = Acc: %86,18
[13]	DIARET DB1	- FRCNN ile feature extraction, fuzzy k-means segmentasyon	FRCNN - ConvNet	Avr = 0.9526
[14]	EyePACS & IDRiD	- Resized (512x512) - Local Average Color %50 - Data Augmentation	Inception-ResNet-V2, Xception (CNN)	Kappa = 0.88
[15]	MESSIDOR, DIARETDB, STARE	- Gürültü temizlemek için rgb to gray scale - 3x3 komşuluk matrisi ile ortanca filtre uyg.	CNN	Acc = %98.5
[16]	EyePACS	- Feature extraction with CNN	VGG16 CNN	Acc = %74,.18 ~ %75,83
[17]	EyePACS	- Resize image - Crop image - Normalize - Augment	VGG-NiN	AUC = %83.8
[18]	DIARETDB1 & APTOS 2019	- CLAHE - Data Augmentation	ResNext(softmax) + DenseNet(Softmaz) Ensemble	NDR vs. DR Acc = %96.98 NDR, Mild,Moderate,Severe,PDR Acc = %86.08
[19]	MESSIDOR DR	Gürültü azaltma, Histogram tabanlı segmentasyon, Renk kanallarına ayrılma, Ana renklerin tanınması, Bölgesel birleştirme, Tepe noktalarının belirlenmesi	Synergic Deep Learning (SDL)	Accuracy = %99.28
[20]	EyePACS	Ön İşleme, Veri Artırma Teknikleri	CNN, ReLU, QWK	Accuracy = %85.7
[21]	Messidor-2	Resized 1200x960, normalizasyon	InceptionV3	Accuracy = %92.55
[22]	Diabetic Retinopathy Detection (2015) ve Aptos 2019 Blindness Detection	Görüntü iyileştirme algoritması	DenseNet	Accuracy = %78
[6]	EyePacs	Veri artırma yöntemleri: Contrast Limited Adaptive Histogram Equalization (CLAHE), Gaussian Blur	VGG-16	Training Accuracy = %92.51 Validation Accuracy = %89.20
[24]	MESSIDOR ve IDRiD dataset	Arka plan segmentasyonu ve kaldırma, Özellik Optimizasyonu	CNN	Messidor Acc = %97.55 Idrid Acc = %98.02
[25]	EyePacs	Resized 512x512, Siyah olanlar çıkarıldı, data augmentation, Dropout, Batch normalization, Binary cross entropy kayıp fonksiyonu	CNN, SVM	Sensitivity = %93 Specificity = %85
[26]	Diabetic Retinopathy Detection	Resized 786 × 512, upsampling ve downsampling, normalizasyon	Stack modeli (Resnet50, Inceptionv3, Xception, Dense-121, Dense169)	Acc (0.01) = %15 (0.001) = %50, (0,0001) = %55, (1.00E-05) = %70

[27]	Diabetic Retinopathy Detection Competition in the Data Modeling and Data Analysis Competition Platform	düşük değerli piksellerin kesilmesi ve dairesel bir görüntü oluşturma	Inception V3, InceptionResNet V2, Xception, ResNeXt101, ve NASNetLarge.	AUC: %95, Accuracy: %92
[28]	Auckland Regional Telemedicine ROP (ART-ROP) image library	Graded sınıflandırması (normal ve plus hastalık olarak) Veri setinin eğitim ve doğrulama setlerine bölünmesi (80:20)	CNN, TensorFlow'in Inception-v3 modeli	sensitivity: %96.6, specificity: %98.0 accuracy: %97.3, AUROC: 0.993
[29]	OCT image database (Version 3)	Border cleaning, Saturation, Segmentation, Channel extraction, Median filtering, Binarization, Object removal, Object merging, ROI selection, Resizing	AlexNet VGGNet GoogLeNet DenseNet-201	Accuracy: %98.6 Specificity: 0.995 Precision: 0.986
[30]	Diaret Dataset and End to End deep ensemble network from kaggle	Gaussian Blurring, Bilateral Filtering, ve Image Blurring	CNN(RELU)	Sensitivity: %92.65, Specificity: 1.000 Accuracy: %96.12, Precision: %94
[11]	APTOS 2019 Blindness Detection	the green channel, CLAHE, morphological close, and background exclusion	CNN	accuracy: %95.35
[32]	R. Diabetic Retinopathy Detection from Fundus Images of the Eye Using Hybrid Deep Learning Features.	1000 piksel çözünürlüğe yeniden boyutlandırma, 90 ve 180 derece döndürme	AlexNet and ResNet101, SVM, Ant Colony	accuracy: %93
[33]	Diagnosing and Predicting Clinical and Para-clinical Cutoffs for Diabetes Complications in Lur and Lak Populations of Iran: A ROC Curve Analysis to Design a Regional Guideline	Data Cleaning Data Normalization Handling Missing Data Feature Selection	DNN	Accuracy: %82.03 Sensitivity (Recall): %76 Specificity: %80.38 F1 score: %71.82 AUC: %80.4
[7]	DRIVE (Digital Retinal Images for Vessel Extraction)	Green Channel Selection, CLAHE, Noise Reduction, Vascular Structure Enhc., Image Standardization	LDA (Linear Discriminant Analysis) kNN (kth Nearest Neighbor) SVM (Support Vector Machine) DT (Decision Tree) ANN (Artificial Neural Network)	ACC: LDA: %100 kNN: %99.2 SVM: %98.8 DT: %99.8 ANN: %100
[35]	B. Kaggle diabetic retinopathy detection competition report	Resizing Images, Applying Green Channel Filter, Applying Various Transformations, Utilizing Preprocessed Images	CNN	Decision Support System (DSS): %67 Accuracy. Statistical Classification: %79.62 accuracy. Fuzzy C-Means (FCM) Clustering: %66 Accuracy.
[36]	APTOS 2019	Deformable Registration, Deformable Registration Application	CNN (Densenet-121, Xception, Inception-v3, and Resnet-50)	Accuracy: %85.28
[9]	Various (e.g., Messidor-2, STARE, DRIVE)	Extraction of region-of-interest, noise removal	Various (e.g., CNN, DNN, Ensemble CNN, DCNN)	Accuracy up to %98.7, Sensitivity up to %99.6, AUC up to 0.95)
[38]	1450 fundus images from the IEEE Data Port	involved cropping images to 150x150 pixels	CNN	Accuracy: %98

Tablo 1: Literatür Özeti

A.3. Beklenen Fayda

A.3.1. Özgün Değer

Literatür taramasında Resnet, DenseNet, Inception gibi birçok derin öğrenme modelinin kullanımı görülmektedir. Hesaplama karmaşıklığı az olan ve daha az parametre ile daha iyi performans gösteren EfficientNet'in Diyabetik Retinopati hastalığı sınıflandırmasında kullanımı ile ilgili çalışmalar mevcut olsa da EfficientNetV2S, EfficientNetV2B0 ve ResNet18 modeliyle ilgili çalışmalar literatürde mevcut değildir. Bu çalışmada, Diyabetik Retinopati hastalığını sınıflandırmada retina damarlarını analiz etme için bu modeller kullanılacaktır. Kullanılan veri seti EyePacs tarafından sağlanan 8000 görsel içeren kapsamlı bir veri setidir.

Çalışmamız ile, diyabetik retinopati hastalığının tanı sürecinde yapay zeka teknolojisinin kullanımını ele almaktadır. Sağlık personelinin diyabetik retinopati teşhisini anında yapabilmesini sağlayacak bir sistem geliştirmektedir. Bu sistem, hastalığın teşhis sürecinde sağlık personelinin etkinliğini artırarak doktorların iş yükünü azaltmayı amaçlamaktadır. Böylece, sağlık sektöründe verimliliği artırmak ve hastalara daha hızlı ve etkili bir sağlık hizmeti sunmak hedeflenmektedir.

A.3.2. Yaygın Etki, Katma Değer

Diyabetik retinopati, dünya genelinde önemli bir sağlık sorunu olarak kabul edilmektedir. Diyabetik retinopati, diyabet hastalarında sık görülen bir komplikasyon olup, görme kaybına neden olma potansiyeline sahiptir. Dünya Sağlık Örgütü (WHO) verilerine göre, dünya genelinde yaklaşık 463 milyon yetişkinin diyabet hastası olduğu tahmin edilmektedir. Diyabetik retinopati, diyabetli bireylerin yaklaşık üçte birinde görülmekte olup, diyabetin süresi ve kontrol düzeyi ile ilişkilidir. Görme kaybı, diyabetik retinopatinin ilerlemesiyle artan bir risktir ve dünya genelinde körlüğün önde gelen nedenlerinden biridir.

ABD Hastalık Kontrol ve Önleme Merkezi, ABD'de 9,6 milyon kişinin diyabet hastası olduğunu tahmin ediyor. Diyabetli Amerikalıların yaklaşık %40 ila %45'inde hastalığın bir aşaması vardır.

Diyabetik retinopati, sadece bireylerin sağlık durumunu olumsuz etkilemekle kalmaz, aynı zamanda ekonomik ve sosyal açıdan da büyük bir yük oluşturmaktadır. Görme kaybı, bireylerin iş gücüne katılımını azaltabilmekte ve yaşam kalitesini önemli ölçüde düşürebilmektedir. Ayrıca, görme kaybıyla ilişkili sağlık hizmetlerinin maliyeti de oldukça yüksektir.

Yapay zeka tabanlı teşhis sistemlerinin kullanımı, diyabetik retinopatinin erken teşhisinde ve yönetiminde önemli bir araç olabilmektedir. Bu sistemler, sağlık personelinin iş yükünü azaltabilmekte, tanı sürecini hızlandırabilmekte ve hastalara daha hızlı ve etkili bir sağlık hizmeti sunabilmektedir. Bu şekilde, diyabetik retinopatiyle ilişkili körlük ve görme kaybı vakalarının önlenmesine ve azaltılmasına katkıda bulunarak sağlık sektörüne önemli bir katma değer sağlamaktadır.

A.4. Yöntem

A.4.1. Veri Seti

Bu çalışmada kullanılan veri setleri, Kaggle platformundan temin edilmiştir. İlk kullanılan veri seti, uluslararası bir yarışma için oluşturulmuş olup, 35127 adet sağ ve sol retina görüntüsünü içermektedir. Makine kısıtları sebebiyle görsellerin tamamı kullanılamamıştır. Görseller, diyabetik retinopati tanısında


kullanılmak üzere derlenmiş ve etiketlenmiştir. İkinci aşamada kullanılan veri seti 224 x 224 boyutlu, Gauss filtresi uygulanmış 3662 adet sağ ve sol retina görüntüsü içermektedir.

Veri setleri üzerinde yapılan işlemler arasında data augmentation bulunmaktadır. Bu işlem, görsellerin çeşitliliğini artırmak, sınıfları dengelemek ve modelin genelleme yeteneğini geliştirmek amacıyla uygulanmıştır.


İlk kullanılan veri seti, eğitim verisi olarak toplamda 10622 görsel içermektedir. İçerdiği görsellerin boyutu (10622, 224, 224, 3) olarak belirlenmiştir. Etiketlerle birlikte veri seti boyutu (10622, 1) şeklindedir. Doğrulama veri seti, 2276 görselden oluşmakta ve boyutu (2276, 224, 224, 3) olarak belirlenmiştir. Etiketlerle birlikte doğrulama veri seti boyutu (2276, 1) şeklindedir. Test veri seti ise 2277 görselden oluşmakta ve boyutu (2277, 224, 224, 3) şeklindedir. Etiketlerle birlikte test veri seti boyutu (2277, 1) olarak belirlenmiştir.

Kullanılan ikinci veri seti toplam 3662 retina görüntüsü içermektedir. Veri artırma işleminin ardından elde edilen retina görüntüsü sayısı 12500 olmuştur. Kullanılan veri seti içerisinde bulunan görsellerin boyutu (12500, 224, 224, 3) olarak belirlenmiştir. Eğitim verisi olarak 7000 görsel kullanılmıştır. Doğrulama veri seti, 3000 görsel içermektedir. Test verisi ise 2500 görselden oluşmaktadır.

Bahsedilen veri setleri, diyabetik retinopati tanısı konusunda derin öğrenme modellerinin eğitilmesi ve değerlendirilmesi için kullanılmıştır. Görsel veri setinin büyüklüğü ve çeşitliliği, modelin genelleme yeteneğini artırarak etkili bir şekilde hastalığı teşhis etme yeteneğini güçlendirmektedir. Aşağıda Şekil 1 ve 2’ de veri setlerinden kesitler sunulmuştur.



Şekil 1: Birinci Veri Setine Dair Örnekler



Şekil 2: İkinci veri setine ait görüntüler

A.4.2. Veri Ön İşleme ve Model Oluşturma

Önerilen yöntemin veri ön işleme ve model oluşturma aşaması python programla dili ile gerçekleştirilmiştir. Modelin oluşturulması ve eğitimi aşamasında, çeşitli görüntü işleme ve derin öğrenme teknikleri kullanılmıştır. Ayrıca, Google Colab bulut hizmeti kullanılarak modelin eğitimi gerçekleştirilmiştir.

Veri ön işleme aşamasında, görüntüler üzerinde çeşitli işlemler uygulanmıştır. Bu işlemler arasında görüntülerin belirli bir şekilde kırılması ve Gauss filtresi uygulanması bulunmaktadır. Ayrıca, veri artırma (augmentation) ve normalizasyon işlemleri de uygulanarak veri setinin çeşitliliği artırılmış ve modelin daha iyi genelleme yapması sağlanmıştır.

Model oluşturma aşamasında, derin öğrenme modeli için uygun bir mimari seçilmiş ve gerekli işlemlerin gerçekleştirilmesi için OpenCV, NumPy, Matplotlib, Pandas ve PyTorch kütüphaneleri kullanılmıştır. Bu kütüphaneler, görüntülerin işlenmesi ve verilerin manipülasyonu gibi işlemleri gerçekleştirmek için kullanılmıştır. Model eğitimi sürecinde ise, PyTorch ve TensorFlow kütüphaneleri kullanılarak derin öğrenme modeli oluşturulmuş ve eğitilmiştir.

A.4.3. Web Uygulaması

Yapay zeka modeli ile web uygulaması arasındaki iletişim, RESTful servisleri kullanılarak sağlanacaktır. Doktorların bir görüntüyü sınıflandırmak istediğinde, RESTful servisler aracılığıyla kolayca bağlantı sağlamaları mümkündür. Bu sistemde, modele ait REST ara yüzü Python programlama dili ile Flask kütüphanesi kullanılarak gerçekleştirilmiştir. Flask, hafif ve esnek bir web uygulama çerçevesi olup, RESTful servislerin kolayca oluşturulmasına olanak tanımaktadır.

Bu web uygulaması sayesinde, sağlık personeli, görüntülerin sınıflandırılması ve diyabetik retinopati tanısının konulması için geliştirilen yapay zeka modeline kolayca erişebilmektedirler. Bu da hastaların tanı ve tedavi sürecinin hızlanmasına ve daha etkili bir şekilde yönetilmesine olanak sağlamaktadır.

A.5. Araştırma Olanakları

Bu bölümde, projenin yapımı sırasında kullanılan bilgisayarların listesi Tablo 1’de, donanım ve fiyat bilgileri ise Tablo 2’de sunulmuştur.

Projede Kullanılacak Mevcut Makine – Teçhizat Listesi (*)	
Adı/Modeli	Projede Kullanım Amacı
Bilgisayar	Veri tabanı ve Web uygulamasının geliştirilmesi
Bilgisayar	Veri tabanı ve Web uygulamasının geliştirilmesi
Eğitim Bilgisayarı	Yapay zeka modelinin eğitilmesi, test edilmesi ve veri ön işleme sürecinin gerçekleştirilmesi
Eğitim Bilgisayarı	Yapay zeka modelinin eğitilmesi, test edilmesi ve veri ön işleme sürecinin gerçekleştirilmesi

Tablo 2: Makine Listesi

Projede Kullanılacak Bilgisayarların Donanım ve Fiyat Bilgileri		
Adı/Modeli	Donanım Bilgileri	Fiyat
Bilgisayar	<ul style="list-style-type: none">- Marka Model:Hp Pavilion 15-dk0006nt- İşlemci: Intel® Core (TM) i5-9300H CPU @ 2.40GHz- RAM: 16 GB- Ekran Kartı: Nvidia GeForce GTX 1650	15000 TL
Bilgisayar	<ul style="list-style-type: none">- Marka Model:MONSTER TULPAR T5 V19.2- İşlemci: Intel® Core (TM) i7-10750H CPU @ 2.60GHz- RAM: 16 GB- Ekran Kartı: Nvidia GeForce RTX 2060	20000 TL
Eğitim Bilgisayarı	<ul style="list-style-type: none">- Marka Model:MONSTER Abra A5 V20.2- İşlemci: Intel® Core (TM) i5-13500H CPU @ 3.50-4.70GHz- RAM: 32 GB- Ekran Kartı: Nvidia GeForce RTX 4050	26000 TL
Eğitim Bilgisayarı	<ul style="list-style-type: none">- Marka Model:MONSTER Abra A5 V15.2- İşlemci: İşlemci Intel(R) Core(TM) i7-9750H CPU @ 2.60GHz- RAM: 16 GB- Ekran Kartı: Nvidia GeForce GTX 1650	15000 TL

Tablo 3: Donanım Fiyat Listesi

A.6. Çalışma Takvimi

A.6.1. İş Zaman Çizelgesi

Yapılacak İş	Tarih																			
	Şubat				Mart				Nisan				Mayıs				Haziran			
	H 1	H 2	H 3	H 4	H 1	H 2	H 3	H 4	H 1	H 2	H 3	H 4	H 1	H 2	H 3	H 4	H 1	H 2	H 3	H4
Problemin tanımlanması																				
Literatür araştırması																				
Fizibilite çalışması																				
Sistem gereksinimlerinin belirlenmesi																				
Diyabetik Retinopati hastalığı tespiti modelinin oluşturulması																				
Diyabetik Retinopati hastalığı sınıflandırma modelinin oluşturulması																				
Prototip çalışmasının yapılması																				
Anket ve analiz çalışması																				
Kullanıcı arayüz tasarımı																				
Ara rapor ve sunum hazırlanması																				
Model çalıştırılması																				
Web uygulamasının yapılması																				
Web uygulamasının test edilmesi																				
Final rapor ve sunum hazırlanması																				

Tablo 4: İş Zaman Çizelgesi

A.6.2. Kişi İş Açıklaması

Avni Faruk Muratoğlu	Göknur Sevinç	Sinan Kompas	Şevval Kolaca
Problemin tanımlanması	Problemin tanımlanması	Problemin tanımlanması	Problemin tanımlanması
Literatür çalışması	Literatür çalışması	Literatür çalışması	Literatür çalışması
Fizibilite çalışması	Fizibilite çalışması	Fizibilite çalışması	Fizibilite çalışması
Gereksinimlerin belirlenmesi	Gereksinimlerin belirlenmesi	Gereksinimlerin belirlenmesi	Gereksinimlerin belirlenmesi
Veri setinin oluşturulması	Veri setinin oluşturulması	Veri setinin oluşturulması	Veri setinin oluşturulması
Anket ve analiz çalışması	Anket ve analiz çalışması	Diyabetik Retinopati hastalığı tespit modelinin oluşturulması	Diyabetik Retinopati hastalığı tespit modelinin oluşturulması
Kullanıcı arayüz tasarımı	Kullanıcı arayüz tasarımı	Diyabetik Retinopati hastalığı sınıflandırma modelinin oluşturulması	Diyabetik Retinopati hastalığı sınıflandırma modelinin oluşturulması
Ara rapor ve sunum hazırlanması	Ara rapor ve sunum hazırlanması	Ara rapor ve sunum hazırlanması	Ara rapor ve sunum hazırlanması
Model çalıştırılması	Model çalıştırılması	Model çalıştırılması	Model çalıştırılması
Web uygulamasının yapılması	Web uygulamasının yapılması	Web uygulamasının yapılması	Web uygulamasının yapılması
Web uygulamasının test edilmesi	Web uygulamasının test edilmesi	Web uygulamasının test edilmesi	Web uygulamasının test edilmesi
Final rapor ve sunum hazırlanması	Final rapor ve sunum hazırlanması	Final rapor ve sunum hazırlanması	Final rapor ve sunum hazırlanması

Tablo 5: Kişi İş Açıklaması

B. ANALİZ

B.1. Sistem Gereksinimlerini Ortaya Çıkarma Yöntem ve Teknikleri

B.1.1. Yüz Yüze Görüşme

Projenin başlangıç aşamasında projenin amacını, kapsamını ve projenin izleyeceği yolu belirleyebilmek için proje danışmanı Öğr. Gör. Dr. Yıldırar ANAGÜN ile görüşmeler yapılmıştır. Fikir ve yöntem tamamı ile danışman hocamıza aittir. Projenin geliştirme sürecinde yapılan görüşmeler ve sonrasında alınan geri dönüşler ile projede ilerleme kaydedilmektedir.

B.1.2. Yazılı Basılı Belge İnceleme

Bu projenin başlangıç aşamasında, diyabetik retinopati tanı sürecinde kullanılan mevcut yöntemler ve bu alandaki teknolojik ilerlemeler detaylı bir şekilde incelenmiştir. Diyabetik retinopati, diyabet hastalarında ortaya çıkan ve tedavi edilmediği takdirde körlüğe yol açabilen bir retinopati türüdür. Bu durum, dünya genelinde milyonlarca insanı etkileyen önemli bir sağlık sorunudur.

Mevcut tıbbi uygulamalarda, diyabetik retinopati teşhisi genellikle fundus fotoğrafları kullanılarak göz doktorları tarafından yapılmaktadır. Bu süreç, göz tabanının detaylı bir şekilde incelenmesini gerektirmekte ve zaman almaktadır. Araştırmalar, derin öğrenme tabanlı yöntemlerin, özellikle konvolüsyonel sinir ağları (CNN) kullanılarak, bu görüntülerin otomatik olarak analiz edilmesi ve hastalığın evresinin sınıflandırılmasında büyük potansiyel taşıdığını göstermiştir (Gulshan et al., 2016).

Özellikle, Kaggle'ın Diabetic Retinopathy Detection dataset gibi büyük veri kümeleri üzerinde yapılan çalışmalar, CNN modellerinin, manuel teşhis yöntemleri ile karşılaştırıldığında benzer veya daha iyi performans gösterebildiğini ortaya koymuştur (Pratt et al., 2016). Bu modeller, görüntüler üzerinde otomatik olarak patolojik değişiklikleri tespit edebilmekte ve teşhis sürecini hızlandırabilmektedir.

Ancak, bu sistemlerin klinik ortamda uygulanması, veri setlerinin kalitesi ve çeşitliliği, modelin genelleştirilebilirliği ve farklı demografik özelliklere sahip popülasyonlarda doğruluğu gibi çeşitli zorluklarla karşı karşıyadır. Ayrıca, bu modellerin karar verme süreçlerinin şeffaf olmaması, etik kaygıları da beraberinde getirmektedir.


Projemiz, diyabetik retinopati sınıflandırmasında derin öğrenme modellerini kullanarak, tanı sürecini otomatize etmeyi ve bu süreci daha hızlı ve etkin hale getirmeyi hedeflemektedir. Özellikle, modelimizin farklı demografik gruplar üzerindeki performansını değerlendirerek, geniş bir hasta yelpazesine uygulanabilirliğini artırmayı amaçlamaktayız. Bu çalışma, diyabetik retinopati teşhisinde yapay zeka tabanlı sistemlerin potansiyelini ve klinik uygulamadaki zorluklarını ele alacak şekilde tasarlanmıştır.

B.1.3. Anket

Anket çalışmasının ilk kısmında hastalara yapay zeka ile hastalığa teşhis koyan bir sağlık sistemine güvenip güvenemeyeceklerini, mevcut düzendeki davranışlarını ve sistem ihtiyaçlarını analiz etmek amacıyla çeşitli sorular sorulmuştur. Anket 103 kişi üzerine uygulanmıştır. Şekil 1, Şekil 2 ve Şekil 3' de gösterilen anketin üç sorusu, hastaların teşhis sürecinde nasıl bir yöntemi tercih ettiklerini öğrenmek amacıyla hazırlanmıştır. Verilen cevaplarda görüldüğü gibi hastaların %65' i hastalık teşhisinde bir yapay zeka sistemine güvendiği gözlemlenmiştir. Hastalığın teşhisinin konulması sürecinde hastaların %27.2' si yapay zeka ile anında teşhisin konulmasını istediklerini bildirmişlerdir. Yapay zekanın teşhis koyduğu bir hastalıkta ise hastaların %84.5' i sonucun yine de doktor tarafından değerlendirmesini istedikleri


gözlemlenmiştir. Yapılan anket ile sistemin gerekliliği hakkında veri elde edilmiş olup anketteki sorular ve sonuçları aşağıdaki grafiklerde detayları ile sunulmuştur.

Hastalarınızın Diyabetik Retinopati görüntülerine göre yapay zekanın hastaya doğru teşhis koyduğuna ne kadar güvenirsiniz? (1-5 arası, 5 çok güvenirim olmak üzere derecelendiriniz.)
27 yanıt




Şekil 2: Doktor Anket Sorusu 1

Hastalarınızın teşhisi koymayı nasıl tercih edersiniz?
27 yanıt



Şekil 3: Doktor Anket Sorusu 2


Aşağıdakilerden hangisi hastalığa teşhis koyan bir yapay zeka sisteminin getireceği olumlu etkiler arasındadır?
27 yanıt



Şekil 4: Doktor Anket Sorusu 3

Diyabetik Retinopati teşhisinde hastalık teşhisini yapay zekanın koymasına güvenir misiniz?


103 yanıt



Şekil 5: Vatandaş Anket Sorusu 1

Yapay zekanın teşhis koyduğu bir hastalıkta, yine de doktorunuzun değerlendirmesini ister misiniz?


103 yanıt



Şekil 6: Vatandaş Anket Sorusu 2

Hastalığınızın teşhisinin konuşulması sürecinde hangisini seçersiniz?

103 yanıt




Şekil 7: Vatandaş Anket Sorusu 3

B.1.4. Gözlem


Proje kapsamında yapılan literatür taraması, yüz yüze görüşme, anket çalışması ve araştırmalar sonucunda bu projenin gerçekleştirilebileceği, hekimler tarafından kullanılabilmesiyle verilerle kanıtlanmıştır. Bununla birlikte proje ilk olarak sadece belirli bir alan üzerinde uygulanabilmesine rağmen model başarısı ile ilerleyen süreçte hastane veya sistemi kullanan hekimlerin isteklerine ve geri bildirimlerine göre gelişmesi mümkün olabilecektir.

B.1.5 Prototip ve Hızlı Uygulama Tasarım (Rapid Application Design- RAD)

Kullandığımız veri seti üzerinde öncelikle hangi modeli tercih edeceğimizi belirleyebilmek için ilk olarak diyabetik retinopati sınıflandırması sağlayacak yapay zeka modelleri geliştirilmiştir. Model eğitimleri colaboratory platformu ve Visual Studio Code üzerinde Python programlama dili kullanılarak yazılmıştır. Kullanıcı ara yüzü olan bir web uygulaması geliştirileceği için örnek tasarımlar yapılmıştır. Eğitilen modellerin başarı oranları Şekil 8 ve Şekil 9’ da ve tasarlanan kullanıcı sayfaları Şekil 10 ve 11’ de gösterilmektedir.



Şekil 8: EfficientNetB20 Model Performansı Başarı ve Kayıp Grafiği



Şekil 9: EfficientNetV2S Model Performansı Başarı ve Kayıp Grafiği

Model performans sonuçlarına bakıldığında eğitim verisi ve doğrulama verisi değerleri birbirlerine paralellik göstermektedir. İki model arasından daha az eğitilebilir parametreye sahip olan EfficientNetV2S modeli daha iyi bir başarı oranı sağlamaktadır.

Şekil 10: Hasta İşlemleri Görsel Yükleme Arayüz Tasarımı

Şekil 11: Hasta İşlemleri Analiz Sonucu Arayüz Tasarımı

B.1.6 Ortak Uygulama Tasarım (Joint Application Design-JAD)

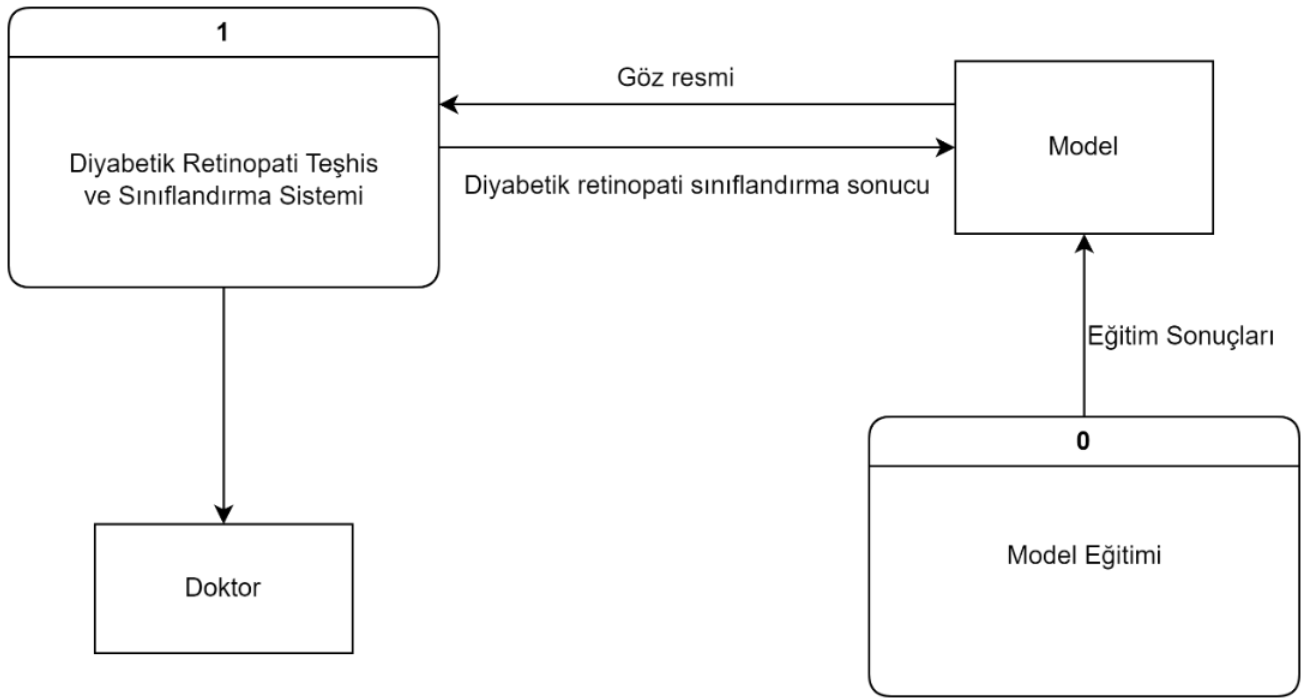
Proje ekibimiz, sistemin son kullanıcıların ihtiyaçlarını tam olarak karşılaması için Ortak Uygulama Tasarımı (JAD), Prototip ve Hızlı Uygulama Geliştirme tekniklerini kapsamlı bir şekilde kullanmıştır. Bu

süreçte, projenin başlangıcından itibaren hem geliştiriciler hem de kullanıcılar aktif olarak yer almıştır. Bu kapsamlı katılım, sistemin gereksinimlerinin doğru bir şekilde belirlenmesine olanak tanımıştır. Projeyi şekillendiren ilk adımda, JAD oturumları düzenlenmiştir. Bu oturumlar, projenin hedeflerini ve kapsamını belirlemek, kullanıcı gereksinimlerini doğru bir şekilde anlamak ve projenin temel fonksiyonlarını tanımlamak için hayati öneme sahiptir. Oturumlar sırasında, tüm paydaşların görüşleri dikkate alınmış, herkesin sesi eşit bir şekilde dinlenmiştir.

B.1.7 Veri Akış Şemaları

B.1.7.1 Kavramsal Veri Akış Şeması

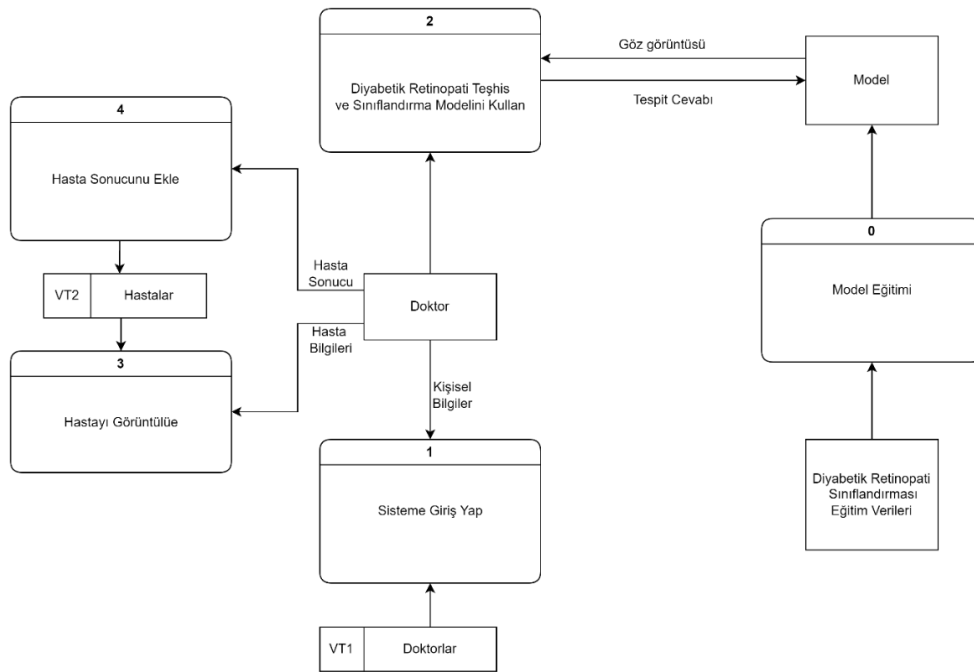
Kavramsal veri akış şemasında hastane çalışanlarının web uygulamasını kullanırken gerçekleştirdiği süreçler gösterilmektedir. Akış şemasına göre sistemde rol doktora aittir. Sağlık çalışanı sisteme öncelikle hastadan alınmış retina görüntülerini yüklemektedir. Görüntüdeki hastalığın derecesi, sistem aracılığıyla eğitilmiş model tarafından belirlenmektedir. Belirlenen sonuçlar tekrar sistem aracılığı ile hastane çalışanına döndürülmektedir. Sistemin özeti Şekil 12’ de bulunan veri akış şeması’ nda gösterilmektedir.



Şekil 12: Kavramsal Veri Akış Şeması

B.1.7.2 Mantıksal Veri Akış Şeması

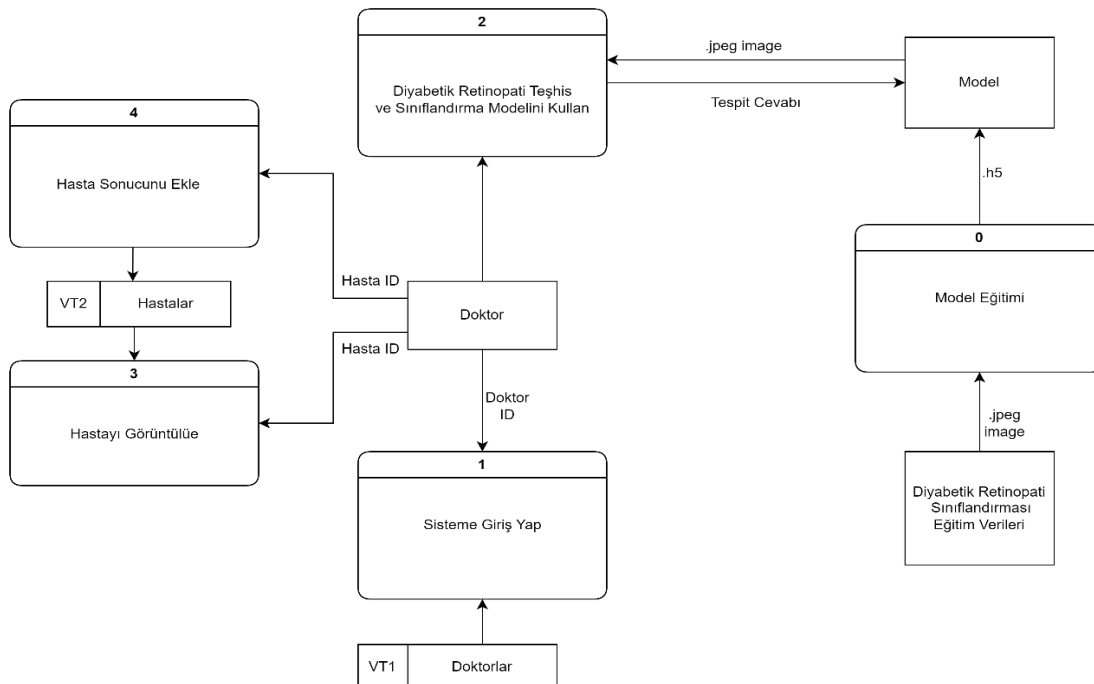
Mantıksal veri akış şemasında, sistem boyunca veri akışlarının gösterilmesi hedeflenmiştir. Mantıksal veri akış şeması, 2 varlık ve 3 işlemden oluşmaktadır. Sistemdeki varlıklar ve işlemler arasındaki veri akışı maddeler halinde aşağıda açıklanmıştır. Model isimli varlık diyabetik retinopati işlemini gerçekleştiren yapay zeka modelidir ve Model Eğitimi (0) işlemi sonucunda oluşur. Bu işlemin girdisi Eğitim Veri Seti varlığıdır ve yapay zeka modelini eğitmek için bu veri seti kullanılır. Hastane çalışanı varlığı sistemi kullanan hastane çalışanlarının tamamını temsil eder.



Şekil 13: Mantıksal Veri Akış Şeması

B.1.7.3 Fiziksel Veri Akış Şeması

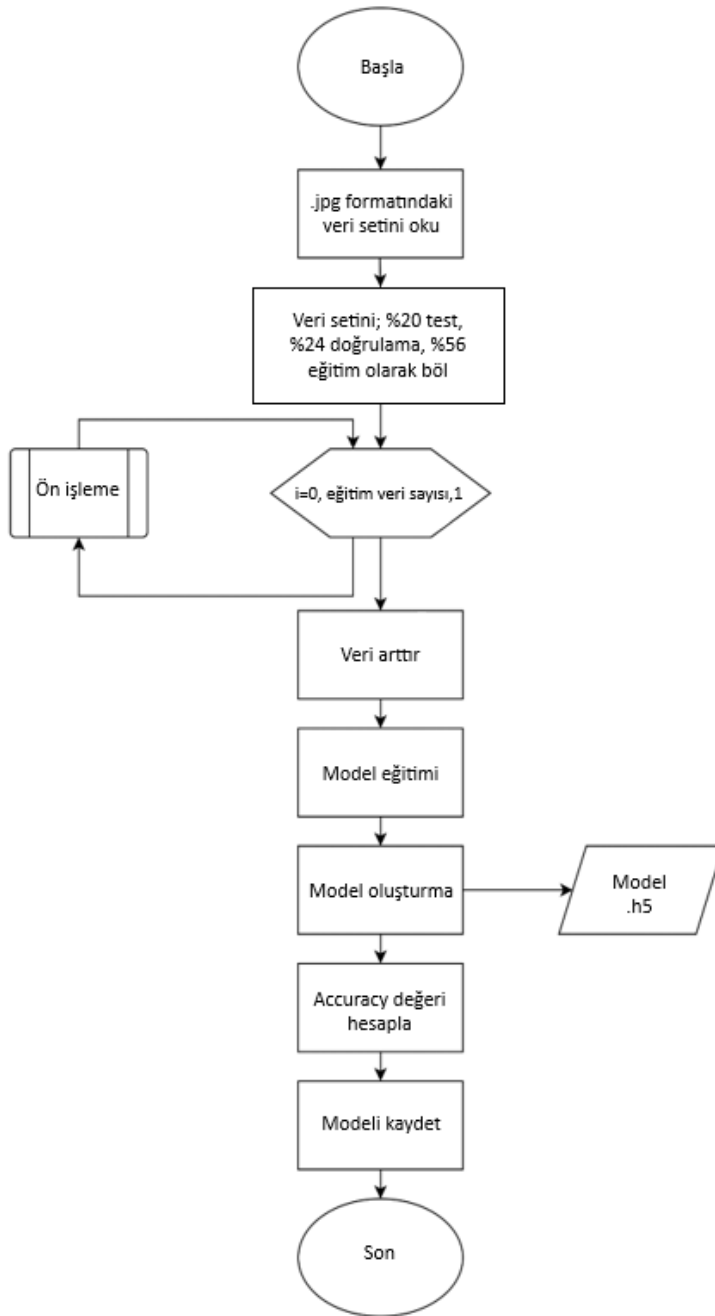
Proje kapsamında verilerin yer değiştirdiği fiziksel ortamlar ve hangi fiziksel yollarla iletilip kaydedildiğini gösteren fiziksel veri akış verilmiştir. Modellerin eğitimi etiketlenmiş .jpeg uzantılı görseller ile yapılmıştır. Eğitilen modeller .h5 uzantılı dosyalara kaydedilmiştir. Hastane çalışanlarının tüm işlemleri web uygulaması üzerinden gerçekleştirilecektir.



Şekil 14: Fiziksel Veri Akış Şeması


B.1.7.4 İş Akış Şeması

Diyabetik retinopati hastalığının sınıflandırmasını yapan yapay zeka modelinin eğitim aşamasının akış şeması aşağıdaki şemada gösterilmektedir. Bu işlemin amacı .jpeg uzantılı görüntü veri setini kullanarak bir yapay zeka modeli geliştirmektir. Veri seti diyabetik retinopati hastalığı bulunan çeşitli seviyelerdeki göz fotoğraflarından oluşmaktadır. Veri setinin %15' i test, %15' i doğrulama ve %70' i eğitim verisi olmak üzere üçe ayrılır. Eğitim veri setindeki her bir görüntü ön işleme aşamasından geçirilerek sınıflandırmayı etkilemeyecek şekilde düzenlenir. Eğitim veri seti sinir ağına verilir ve eğitilir. Eğitim sonrası modelin doğruluk oranı hesaplanır, model .h5 formatında kaydedilir. Modeller, eğitim tamamlandıktan sonra bir web sunucusu aracılığı ile bu sistemi kullanmak için bir paket biçimi olan .h5 formatına dönüştürülerek kaydedilmektedir. Model başarı sonucu test verileri ile hesaplanmaktadır.



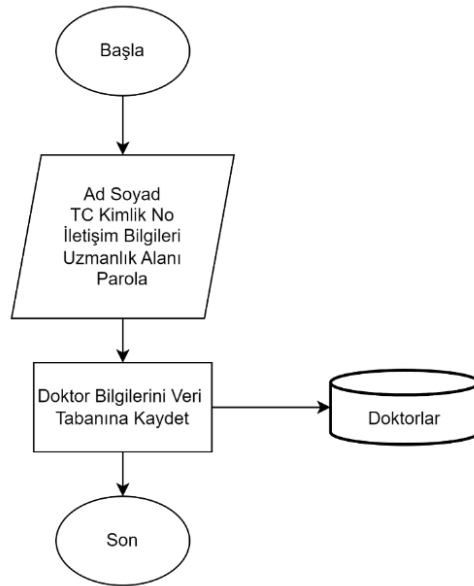
Şekil 15: Yapay Zeka Modeli İş Akış Şeması

Yapay zeka modelinin eğitim aşamasında veri setindeki her bir görüntü ön işleme aşamasından geçirilerek sınıflandırmayı etkilemeyecek şekilde düzenlenmektedir. Şekil 16' daki şemada, ön işleme aşamasının akış şeması gösterilmektedir. Sırasıyla öncelikler görüntü içerisinde bulunan gereksiz alanlar kırılmaktadır. Görseller daha sonra görüntüdeki gürültülerin giderilmesi için Gaussian filtrelemeden geçirilmektedir. Ardından görsellere data augmentation uygulanmaktadır.



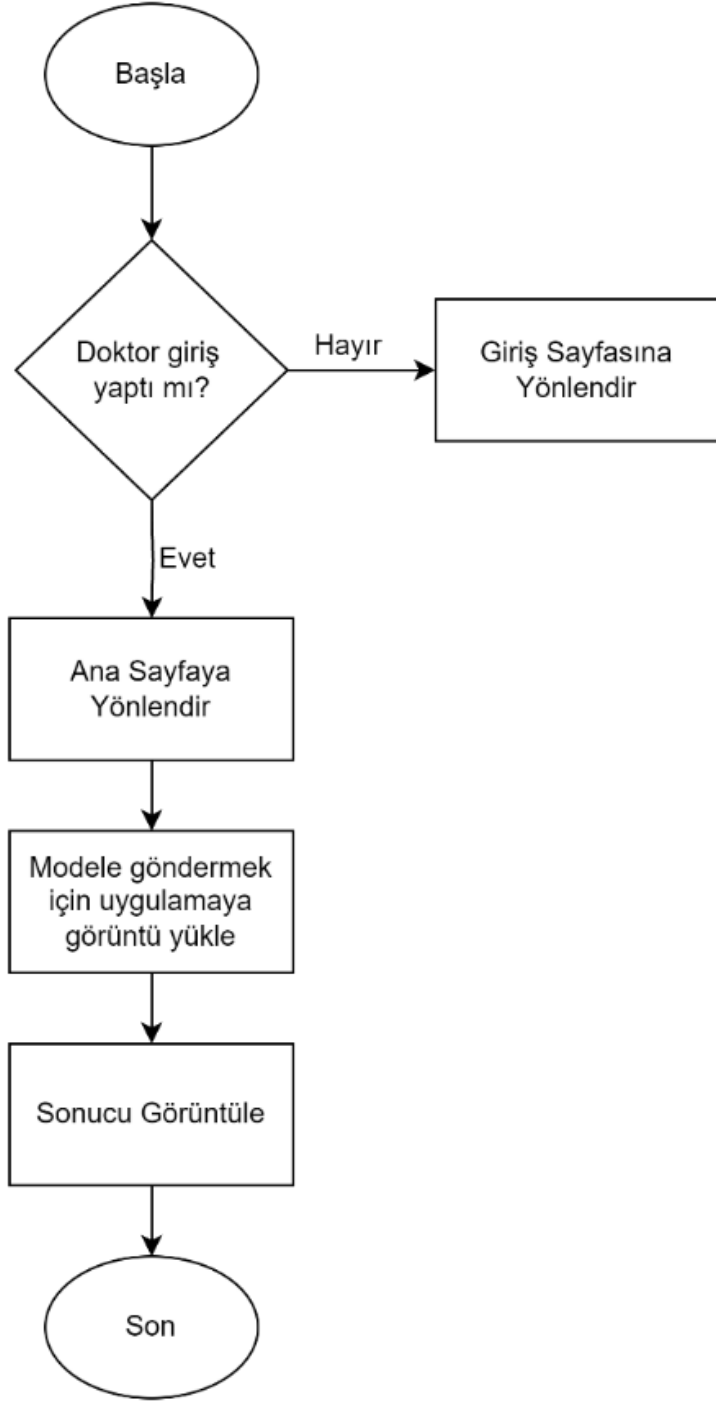
Şekil 16: Ön İşleme Aşaması İş Akış Şeması

Doktor için kayıt işlemi senaryosu iş akış şeması Şekil 17' de gösterilmektedir. Doktor, sisteme her an girebilmektedir. Hastane tarafından çekilen retina görüntüsü modele ara yüz yardımıyla iletilecektir. Model, hastaya ait diyabetik retinopati seviyesi ile ilgili tahminde bulunacaktır.



Şekil 17: Doktor Kayıt İşlemi İş Akış Şeması

Doktor için kullanım senaryosu iş akış şeması Şekil 18’ de gösterilmiştir. Doktor sisteme hastane yönetimi tarafından eklendikten sonra kimlik numarası ve parolası ile sisteme giriş yapabilmektedir. Retina görüntüleri doktor tarafından incelenecek gerekli görüldüğünde modele ara yüz yardımıyla iletilecektir. Model doktora hastanın durumu ile ilgili ikinci bir görüş sunacaktır.



Şekil 18: Doktor Sistem Kullanımı İş Akış Şeması

B.1.8. Olay Tabloları, Durum Formları, İşlevsel Analiz Raporu

B1.8.1 Olay Tabloları

Olay	İstemci	Tetikleyici	İşlem	Yanıt	Hedef
Model oluşturulması	Uygulama	Model eğitim veri seti	Modelin eğitim veri setine göre oluşturulması	Model	Uygulama
Hastane çalışanının model kullanma talebi	Hastane çalışanı	Diyabetik retinopati görüntüsü	Sınıflandırma sonucunun hastane çalışanı tarafından görüntülenmesi	Model	Uygulama
Doktorun sisteme giriş yapması	Doktor	TC Kimlik, Şifre	Doktorların tablosundan kullanıcı adı ve parolanın aranması, eşleşiyorsa uygulamaya yönlendirilmesi	Uygulama	Uygulama
Doktorun hasta bilgilerini görüntülemesi	Doktor	Hasta bilgileri	Veri tabanından hasta bilgilerinin iletilmesi	Uygulama	Doktor
Doktorun modeli kullanma talebi	Doktor	Göz görüntüsü	Sınıflandırma sonucunu doktorun görüntülemesi	Model	Uygulama

Tablo 6: Olay Tabloları

B.1.8.2 Durum Formları

Durum İsmi: Model oluşturma			İşlem No: 1
Tanım: Veri setiyle derin öğrenme modelinin eğitimi			
Tetikleyici: Modeli eğitim veri seti			
Tetikleyici Türü: İç kullanıcı			
Girdi İsmi: Eğitim veri seti	Kaynak: Eğitim veri seti	Çıktı: Model	Hedef: Uygulama

Tablo 7: Durum Formu 1

Durum İsmi: Doktorun sisteme giriş yapması			İşlem No:2
Tanım: TC Kimlik No ve şifre veri tabanındaki kayıtlarla eşleşiyorsa uygulamaya yönlendirilir.			
Tetikleyici: TC Kimlik No, Şifre			
Tetikleyici Türü: Dış kullanıcı			
Girdi İsmi: TC Kimlik No, Şifre	Kaynak: Doktor	Çıktı: Uygulama	Hedef: Uygulama

Tablo 8: Durum Formu 2

Durum İsmi: Doktorun hasta bilgilerini görüntülemesi			İşlem No:3
Tanım: Doktor hastayı görüntüleme işlemi ile hasta bilgilerine erişir.			
Tetikleyici: Hasta bilgileri			
Tetikleyici Türü: Dış kullanıcı			
Girdi İsmi: Hastanın kimlik bilgisi	Kaynak: Doktor	Çıktı: Hasta bilgileri	Hedef: Uygulama

Tablo 9: Durum Formu 3

Durum İsmi: Doktorun model kullanma talebi			İşlem No:4
Tanım: Retina görüntüsü üzerinden hastalık sınıf tespiti			
Tetikleyici: Diyabetik retinopati görüntüsü			
Tetikleyici Türü: Dış kullanıcı			
Girdi İsmi: Retinal Görüntü	Kaynak: Doktor	Çıktı: Hastalık sınıf bilgisi	Hedef: Uygulama

Tablo 10: Durum Formu 4

B.1.8.3. İşlevsel Analiz Raporu

Proje Kodu:

Proje Adı: Derin Öğrenme ile Diyabetik Retinopati Hastalığının Sınıflandırması

Hazırlayanlar: Avni Faruk Muratoğlu, Göknur Sevinç, Şevval Kolaca, Sinan Kompas

Başlangıç Tarihi: 26.02.2024

Son Değiştirme Tarihi: 20.04.2024

Versiyon: 1.1

İlgili Kişi: Dr. Öğr. Üyesi Yıldırar ANAGÜN

Görevi: Proje Danışmanı

Mevcut Sistemlere Etkisi: Diyabetik retinopati hastalığının teşhis ve sınıflandırılmasıyla hastane çalışanlarına daha hızlı ve güvenilir sonuçlar elde etmesinde yardımcı olmak.

Kırtasiye ve Sarf Malzemesi İhtiyacı: Herhangi bir kırtasiye ve sarf malzemesi ihtiyacı bulunmamaktadır.

Dönüştürme: Retinal görüntü ön işleme aşamalarından geçirilerek performans arttırılacaktır.

Donanım: Projenin oluşturulması ve test aşamasında halihazırdaki donanımlar yeterli olacaktır. Fakat gerçek zamanlı çalışmalarda daha iyi sistemlere gerek duyulabilir.

Maliyetler: Lisanslama açısından bir maliyet bulunmamaktadır. Gerçek zamanlı çalıştırılması için donanım ihtiyacından dolayı artış gösterebilir.

Tablo 11: İşlevsel Analiz Raporu

B.2. Sistem Gereksinimleri

B.2.1. İşlevsel Gereksinimler

Hastaların göz görüntülerinden diyabetik retinopati teşhisi ve sınıflandırılması için ilk olarak yapay zeka modeli oluşturulmalıdır. Bu modelin eğitimi için çeşitli derecelerde diyabetik retinopati hastalığına sahip göz verileri etiketlenmelidir.

Sistemi kullanmak için hastane çalışanları web uygulamasına giriş yapmalıdırlar.

B.2.2. Sistem ve Kullanıcı Arayüzleri ile İlgili Gereksinimler

- Sistem bir web uygulaması, yapay zeka modeli ve veri tabanından oluşmaktadır.
- Web uygulaması veri tabanı ve yapay zeka modeli ile iletişim kurmalıdır.
- Sistem kullanıcıları geliştirilecek web uygulamasını kullanmak için bir web tarayıcısı kullanılmalıdır.
- Kullanıcılar göz görüntülerini sisteme yükleyebileceklerdir.
- Kullanıcılara uygulama içerisinde gerekli bilgiler verilerek ve anlaşılır bir arayüz sunularak kullanıcı dostu bir web uygulaması geliştirilmesi planlanmaktadır.

B.2.3. Veriyle İlgili Gereksinimler

- Yapay zeka modeli, web arayüzünde kullanılabilmesi için h5 dosyasında saklanacaktır.
- Modelin çalışacağı sunucu hiç kapanmadan çalışır durumda olmalıdır.
- Kullanıcı parolaları veri tabanında şifrelenmiş bir şekilde saklanacaktır.
- Yapay zeka modeli bir web sunucusu üzerinde çalışacaktır. Retina görüntüleri kullanıcılardan ara yüz aracılığıyla alınacak ve web sunucusuna aktarılacaktır.
- Veri tabanında saklanacak bilgiler daha sonra sınıflandırma yapacak yapay zeka modelinin geliştirilmesi için kullanılabilir.
- Kullanıcılar bilgilerini silmedikleri sürece bilgiler veri tabanında saklanacaktır. Veri tabanı sürekli canlı ve ulaşılabilir olmalıdır.

B.2.4. Kullanıcılar ve İnsan Faktörü Gereksinimleri, Güvenlik Gereksinimleri

- Kullanıcıların sistemi kullanabilmeleri için bir web tarayıcısına ihtiyaçları vardır. Bu nedenle kullanıcıların bir web tarayıcısı kullanmayı bilmeleri gerekmektedir.
- Kullanıcılar gerçekleştirecek uygulamayı kullanmak için herhangi bir eğitime ihtiyaç duymayacaklardır.

B.2.5. Teknik ve Kaynak Gereksinimleri, Fiziksel Gereksinimler

- Web uygulamasını kullanabilmek için web tarayıcı yazılımı bulunan cihazlara ihtiyaç duyulmaktadır.
- Modeli geliştirmek için Python programlama dili kullanılmıştır.
- Yapay zeka modelinin geliştirilmesi CPU veya GPU donanımları ile yapılabilir. GPU daha hızlı model eğitimi sağladığı için model eğitimi GPU ile yapılacaktır. Bunun için ücretsiz GPU desteği sağlayan Google Colab platformu kullanılacaktır.
- Web uygulamasının geliştirilmesi için HTML ve CSS web teknolojileri kullanılmıştır. Geliştirme sırasında oluşacak ihtiyaçlara göre başka teknolojiler de kullanılabilir.

C.TASARIM

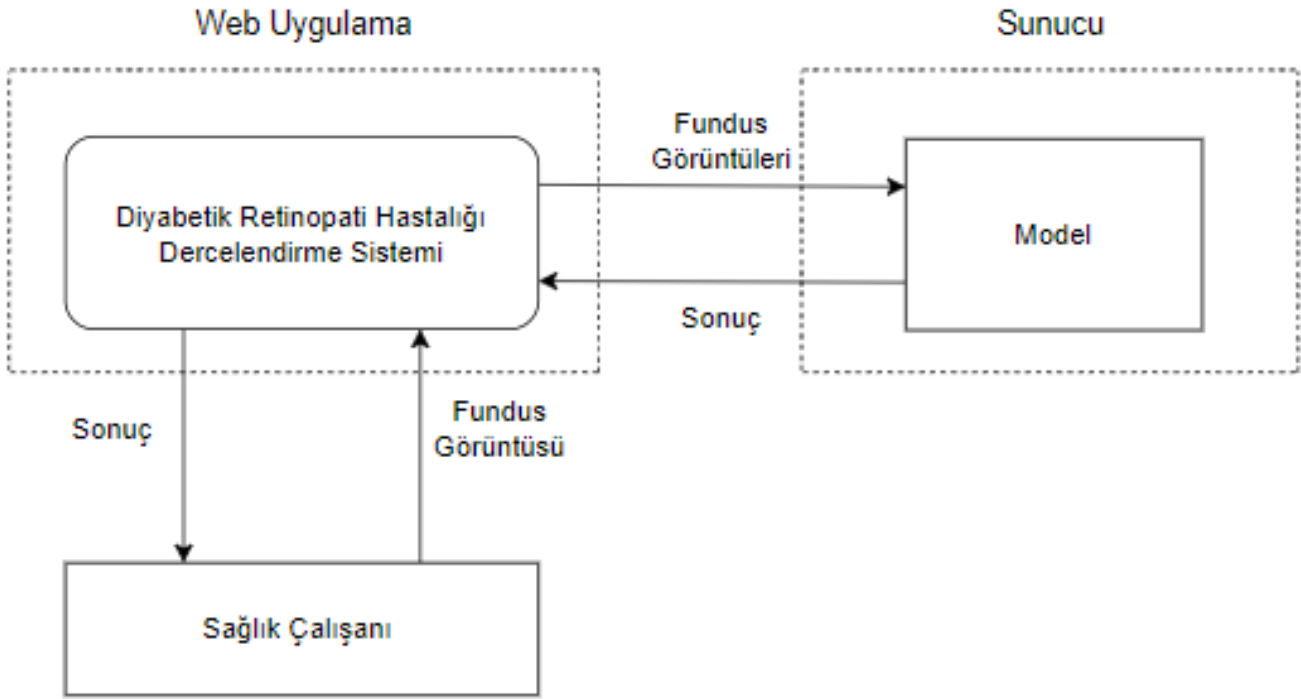
Tasarım bölümü içerisinde sistem tasarımı, kullanıcı tasarımı, sistem arayüzü tasarımı, test tasarımı, yazılım tasarımı, veri tabanı tasarımı ve donanım tasarımı başlıklarından söz edilecektir.

C.1. Sistem Tasarımı

Yapay zeka modeli ile web uygulaması arasındaki iletişimin RESTful servisleri ile sağlanması planlanmaktadır. Bu şekilde sağlık çalışanı elinde bulunan görseldeki hastalığın derecesini öğrenmek istediğinde RESTful servisleri aracılığıyla bağlantı sağlayabilecektir.

Kullanıcı tarafından kullanılacak uygulama HTML, CSS, JavaScript gibi teknolojilerin bir arada kullanılmasıyla gerçekleştirilecektir. Geliştirme esnasında oluşabilecek sorunlar sebebiyle, bahsedilen teknolojiler haricinde farklı teknolojiler de kullanılabilir.

Program, web uygulaması üzerinden alınan görüntüyü sunucuya göndermektedir. Sunucu gelen görüntüyü gerekli işlemlerden geçirerek modele vermektedir. Model görüntüyü analiz ederek hastalığın derecesini belirlemektedir. Belirlenmiş olan derece bilgisi web uygulamasına iletilmektedir. Sistem tasarımı Şekil 19’ da gösterilmektedir.

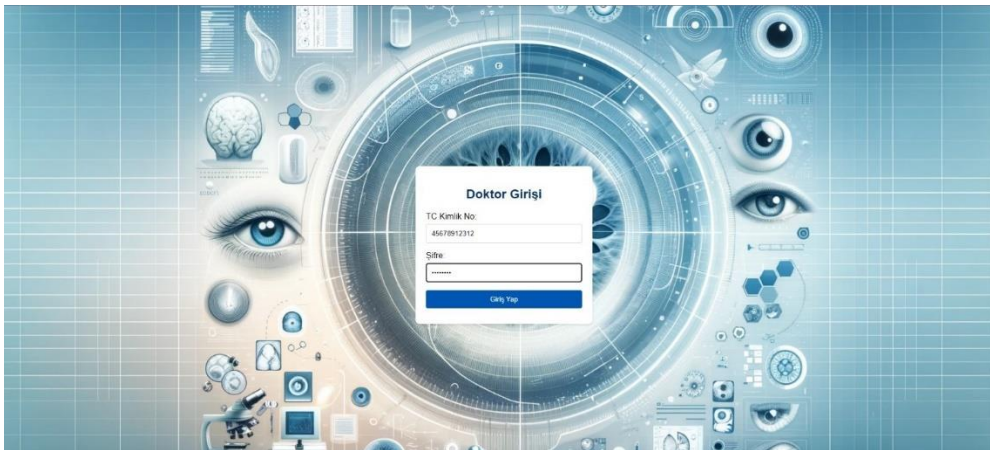


Şekil 19: Sistem Tasarımı

C.2.Kullanıcı ve Sistem Arayüzü Tasarımları

Web uygulamasının arayüzü HTML, CSS ve JavaScript teknolojileri kullanılarak geliştirilmektedir. Kullanıcıların herhangi bir zorluk yaşamaması için arayüz, kullanıcı dostu bir şekilde tasarlanmaktadır. Şekil 20 ve 21’ de arayüz tasarımları görülmektedir.

Web uygulama ara yüzünde herhangi bir oturum açma işlemi gerekmemektedir. Sağlık çalışanı direkt olarak görsel yükleme ekranı ile karşılaşmaktadır. Görüntü seçilerek web uygulamasına yüklenmektedir. Analiz et butonu kullanılarak analiz işlemi gerçekleştirilmektedir. Bahsedilen işlemler sonucunda ekranda, gerçekleşen işlem sonucu yazmaktadır.



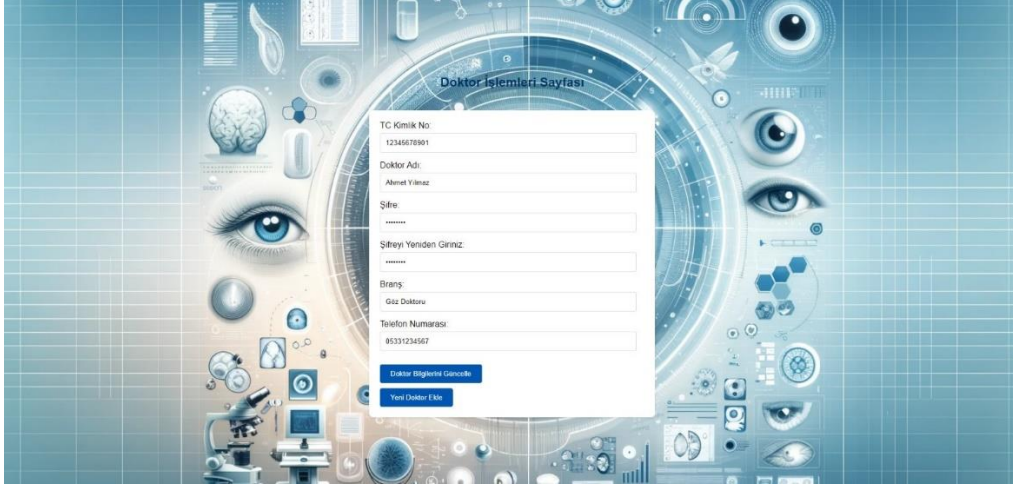
Şekil 20: Giriş Yap Sayfa Tasarımı



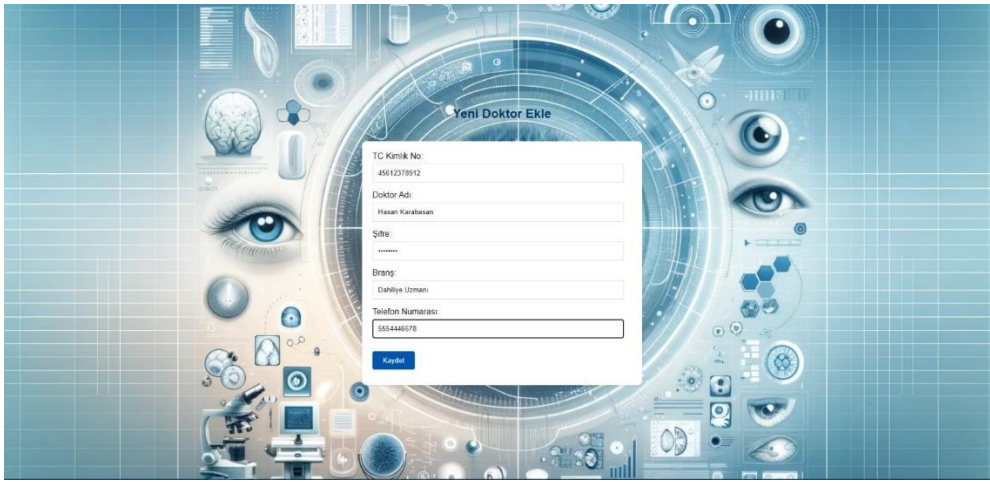
Şekil 21: Hasta ve Doktor İşlemleri Seçim Sayfası

Şekil 22: Hasta İşlemleri Sayfa Tasarımı

Şekil 23: Hasta İşlemleri Sayfa Tasarımı



Şekil 24: Doktor İşlemleri Sayfa Tasarımı



Şekil 25: Yeni Doktor Ekle Sayfa Tasarımı

C.3. Test Tasarım

Yazılım testleri, belirlenen gereksinimlerin ve isteklerin gerçekleştirilen sisteme uygunluğunu değerlendirmek için yapılmaktadır. Bu testler, sistemin belirli koşullar altında nasıl davrandığını anlamak ve olası hataları tespit etmek amacıyla gerçekleştirilmektedir. Ayrıca, sistemin performansını doğrudan etkileyebilecek testler, proje tasarımında büyük önem taşımaktadır. Bu testler, sistemin kullanıcı gereksinimlerini karşılayıp karşılamadığını, istenilen performans seviyelerini sağlayıp sağlamadığını belirlemeye yardımcı olmaktadır.

C.3.1 Gereksinim Analizlerinden Teste Yönelik Hedeflerin Detaylandırılması

- Projede halihazırda bulunan retinal görseller üzerinden derin öğrenme modelinin eğitimi için bir model oluşturulmaktadır.
- Modelin doğruluk oranı her eğitimden sonra hesaplanmaktadır ve bu değerin %90' nın üzerinde olması hedeflenmektedir.
- Modeli test etmek için veri setinin %15' i kullanılmaktadır.
- Sınıflandırmayı yapacak derin öğrenme modeli sunucuda çalıştığı için model çıktısının .h5 formatında olup olmadığı denetlenecektir.

- Yapılacak testler ile derin öğrenme modelinde ve web uygulamasında geliştirme ve iyileştirme yapılarak sistemin en iyi şekilde çalışması hedeflenmektedir.

C.3.2. Fonksiyonel Test Tasarımı

C.3.2.1. Birim (Unit) Testleri Tasarımı

Birim testi tasarımının amacı, projenin geliştirme aşamasındaki hatalarının hızlı bir şekilde giderilmesidir. Bu amaçla aşağıdaki örnek birim test senaryoları oluşturulmuştur.

Test Senaryosu Adı: Doktorun giriş işlemleri
Test Senaryosu Açıklaması: Sistem üzerinde kayıtlı olan cihazı kullanarak sisteme giriş yapar. Cihazında tanımlı olup olmadığı kullanılan kurumun sorumluluğundadır. Hastanın retina fotoğraf çekimi kurum sorumluluğundadır.
Yazılım Hazırlık: Eğitilmiş model erişimi
Donanım Hazırlık: İnternete bağlı bir bilgisayar
Test Adımları: Adım 1: Doktor sisteme kayıtlı olan cihazda uygulamayı açar. Adım 2: Hastanın retina fotoğrafını elde eder.

Test Senaryosu Adı: Diyabetik Retinopati Hastalıkları Sınıflandırma
Test Senaryosu Açıklaması: Doktor elde edilen retina fotoğrafını uygulamaya ekler. Sınıflandırmaların sonucu arayüz üzerinden gösterilir.
Yazılım Hazırlık: Eğitilmiş model erişimi, Tarayıcı
Donanım Hazırlık: İnternete bağlı bir bilgisayar
Test Adımları: Adım 1: Doktor retina fotoğrafını arayüz üzerinden sisteme yükler. Adım 2: Sistem yüklenen fotoğrafı model aracılığıyla işler. Adım 3: Model fotoğrafa gerekli filtrelemeleri, kırpmayı ve boyutlandırma işlemlerini uyguladıktan sonra sınıflandırma işlemini gerçekleştirir. Adım 4: Elde edilen sonuç arayüzde bastırılır.

C.3.2.2. Entegrasyon Testleri Tasarımı

Proje geliştirilirken modüler olarak geliştirilmektedir. Projede arayüz tasarımı HTML, CSS ve javascript ile gerçekleştirilmektedir. Veri tabanı olarak doctor, hasta ve kayıt bilgilerinin tutulması planlanmaktadır. Veri tabanı oluşturulurken PostgreSQL kullanılması planlanmaktadır. Derin öğrenme modelinin eğitilmesi için gerekli olan görseller kaggle aracılığı ile elde edilmektedir. Modelin eğitimi için Colaboratory ve VSCode kullanılmaktadır. Web uygulaması için bir sunucu oluşturulması planlanmaktadır. Web uygulaması, retina görsellerindeki hastalıkları sınıflandırmak için daha önce eğitilmiş olan derin

öğrenme modelini kullanmaktadır. Uygulama, retina fotoğrafındaki hastalığın hangi sınıfa ait olduğu bilgisini eğitilmiş derin öğrenme modeli sayesinde tahmin etmektedir. Tahmin edilen hastalık derecesi ise arayüz aracılığıyla kullanıcıya gösterilmektedir.

C.3.3. Performans Test Tasarımı

Uygulama, başarı yüzdesi en yüksek olan eğitim modeliyle çalıştırıldığı göz önünde bulundurularak hata payının da bulunabileceği bilinerek hizmet veriyor olması ön görülmelidir. Projemiz bir web uygulaması olduğu için uygulamanın her türlü cihaz ve platformda çalışabilir durumda olması planlanmaktadır.

Mevcutta kullanılan eğitim modellerinde yaşadığımız ezberleme problemleri şu an için aktif bir performans problemine sebebiyet vermektedir. Bu ezberleme problemini ön işleme adımlarını düzenleyerek aşmayı planlamaktayız.

Uygulamamız bir web uygulaması olduğundan dolayı arayüzde bulunan butonların sorunsuz bir şekilde kullanılabilir olması beklenmektedir. Arayüz aracılığıyla model bağlantısının hızlı ve sorunsuz bir geri dönüt vermesinde performans kaybına sebep olacak etkenlerin ortadan kaldırılması planlanmaktadır.

Bu bağlamda aşağıdaki tablo 12, 13, 14 ve 15’ te performans testinin sağlanması için gerekli olabileceğini düşündüğümüz sırasıyla yükleme, stres, dayanıklılık ve spike test senaryoları tasarlanmıştır. Bu senaryoların ilerleyen aşamalarda daha optimize bir sistem kurabilmek adına uygulamamıza eklenmesi planlanmaktadır.

Yükleme Testi Amacı: Uygulamanın belirli bir kullanıcı yükü altında nasıl performans gösterdiğini değerlendirmek
Adımlar: 1. Uygulama başlatılır. 2. Belirlenen maksimum kullanıcı yüküne ulaşacak kadar kullanıcılar uygulamaya erişir. 3. Uygulamanın yanıt süreleri ve performansı izlenir. 4. Uygulamanın belirlenen yük altında stabil bir şekilde çalışıp çalışmadığı değerlendirilir.

Tablo 12: Yükleme Test Senaryosu

Stres Testi Amacı: Uygulamanın maksimum kapasitesini aşacak yük altında ne kadar dayanıklı olduğunu test etmek.
Adımlar: 1. Uygulama başlatılır. 2. Maksimum kapasitenin üzerinde bir kullanıcı yükü uygulanır. 3. Uygulamanın yanıt süreleri, hata oranları ve sistem davranışı incelenir. 4. Uygulamanın aşırı yük altında çökme veya hatalı davranışlar sergileyip sergilemediği değerlendirilir.

Tablo 13: Stres Testi Senaryosu

Dayanıklılık Testi Amacı: Uygulamanın uzun süreli kullanımı sırasında performansının nasıl değiştiğini belirlemek.
Adımlar: 1. Uygulama başlatılır. 2. Belirli bir süre boyunca stabil bir kullanıcı yükü uygulanır. 3. Uygulamanın yanıt süreleri ve performansı periyodik olarak izlenir. 4. Uygulamanın uzun süreli kullanım sonrası performansında herhangi bir düşüş veya sorun olup olmadığı değerlendirilir.

Tablo 14: Dayanıklılık Testi Senaryosu

Spike Testi Amacı: Uygulamanın beklenmedik bir şekilde artan kullanıcı yükü altında nasıl tepki verdiğini test etmek.

Adımlar:

1. Uygulama başlatılır.
2. Ani bir şekilde artan bir kullanıcı yükü uygulanır.
3. Uygulamanın yanıt süreleri ve performansı izlenir.
4. Uygulamanın ani yük altında stabil bir şekilde çalışıp çalışmadığı değerlendirilir.

Tablo 15: Spike Testi Senaryosu

C.4.Yazılım Tasarımı


C.4.1. Gereksinime Bağlı Yazılım Kalıpları Seçimi

Uygulama geliştiriciler dışında kullanılacağı için herhangi bir tasarım kalıbı kullanılmasına gerek duyulmamıştır.

C.4.2. UML Kullanarak Tasarım Diyagramı Oluşturma


Model eğitimi fonksiyonel UML diyagramındaki eğitim sınıfı, derin öğrenme modelini eğitmek için kullanılmaktadır. Şekil 21’ deki eğitim sınıfına ait UML diyagramında, eğitim sınıfıyla yapılanlar aşağıdaki gibidir.

- Kullanılacak olan modelin tanımlanması
- Veri setinde bulunan görsellerin boyutlandırılması
- Modelin ön işleme uğramış olan görsellerle eğitilmesi
- Eğitilen model sonuçlarının bastırılması
- Eğitim modelinin .h5 olarak kaydedilmesi




Şekil 25: Eğitim Sınıf UML

Şekil 22’ de App_Model_Tanımlama sınıfına ait eğitilmiş modelin yüklenecek görsel üzerinde çalışmasını sağlayacak uygulamanın UML diyagramı bulunmaktadır. Load_model kısmında daha önce en yüksek doğruluk değerlerine sahip olan modelin yüklenmesini sağlayan fonksiyondur. Eğitilmiş olan model yüklendikten sonra web uygulaması arayüzü aracılığıyla yüklenen hasta ait retina görüntüsü eğitim modeliyle değerlendirmesinde daha yüksek başarı elde etmek üzere çeşitli filtrelemelerin ve yeniden boyutlandırılmasını sağlayacak olan preprocess_image fonksiyonu çalıştırılmaktadır. Son olarak da yüklenen ve işlenen retina görüntüsünün sınıf tahminini yapacak olan predict_image fonksiyonu çalışır ve arayüze bu sonuç yollanmaktadır.



Şekil 26: Model UML

Şekil 23’ te DataSet sınıfına ait veri tabanı üzerinde düzenleme ve erişimi sağlayan fonksiyonların UML diyagramı bulunmaktadır. Bu sınıftaki fonksiyonlar CRUD(create, read, update, delete) işlemlerini gerçekleştirmeye yaramaktadır. Ayrıca getWithTC fonksiyonu hasta TC kimlik bilgisine göre veri tabanından bilgilere erişim sağlamaktadır.



Şekil 27: Model UML

C.5. Veri Tabanı Tasarımı

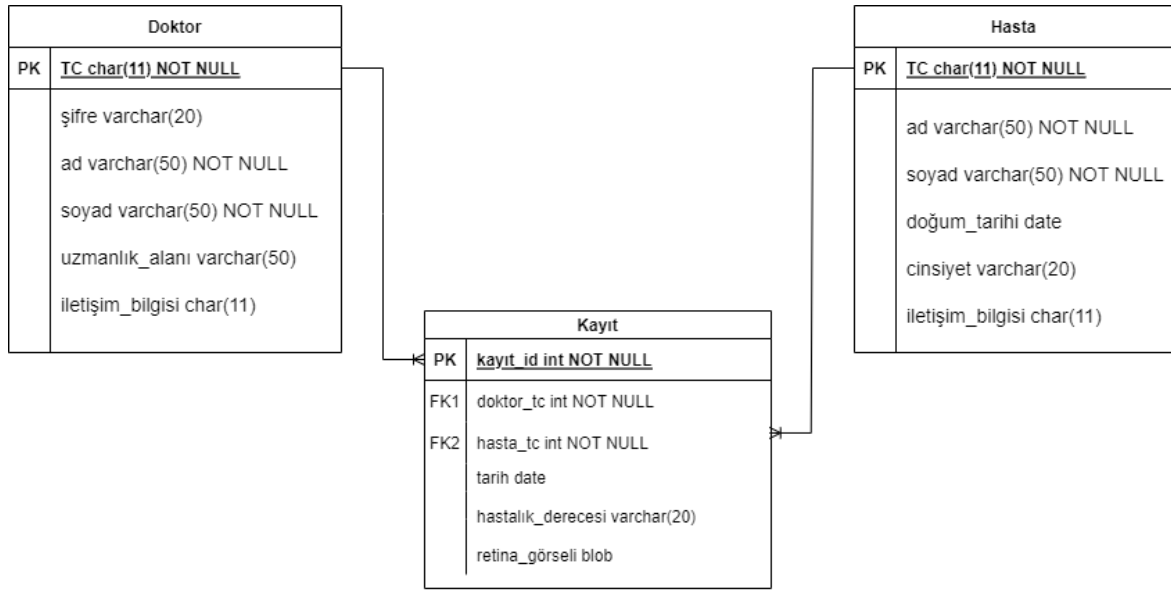
Proje içerisinde veri tabanı işlemleri MySQL kullanılarak gerçekleştirilecektir. MySQL, açık kaynaklı ilişkisel bir veri tabanıdır. İlişkisel bir veri tabanı olması sebebiyle projemizde kullanılması uygun görülmüştür. MySQL, tasarım açısından kullanılabilirliği kolay bir veri tabanıdır.

C.5.1. Veri Tabanı İsterler Dokümanı

- Veri tabanında doktor, hasta ve kaydolmak üzere üç farklı tablo bulunmaktadır. Doktor ve hasta tablolarında birincil anahtar olarak T.C. kimlik numaraları tutulmaktadır. Kayıt tablosunda ise birincil anahtar bilgisi id değişkeni ile sağlanmaktadır.
- Doktor, web uygulamasına giriş yapmak için T.C kimlik numarasını ve şifresini kullanmaktadır. Hasta için uygulamaya giriş yapmak söz konusu değildir.
- Doktorlar hasta kayıtlarına erişebilmektedirler ve sisteme yeni hasta ekleyebilmektedirler. Hasta kaydına erişebilmek için hastanın T.C. kimlik numarasına sahip olmak yeterlidir. Yeni kayıt eklemek için ise hastaya ait T.C kimlik numarası, ad, soy ad, cinsiyet, doğum tarihi ve iletişim bilgileri gerekmektedir.
- Doktorlar, kendilerine ve hastalara ait bilgileri değiştirebilmektedirler.
- Kayıt tablosunda, her hastanın kayıt bilgileri saklanmaktadır ve bu sebeple hastanın T.C. kimlik numarasına referans veren bir yabancı anahtar bulundurmaktadır. Ayrıca, her kaydın hangi doktor tarafından oluşturulduğunu belirtmek için ilgili doktorun T.C kimlik numarasını referans gösteren başka bir yabancı anahtar daha bulunmaktadır.
- Hasta kayıt bilgileri, kaydın oluşturulma tarihini ve hastalık derece bilgisini sağ ve sol göz özelinde saklamaktadır.
- Her hastanın birden fazla kaydı olabilir ancak her kayıt yalnızca bir hastaya ait olabilir. Bu sebeple kayıt ve hasta tabloları arasında bire-çok ilişkisi bulunmaktadır. Ayrıca doktor ve kayıt tabloları arasında da bire-çok ilişkisi bulunmaktadır çünkü her kayıt girişi bir doktora aittir ancak bir doktor birden fazla kayıt girişi gerçekleştirebilmektedir.

C.5.2. E/R Diyagramı

Sisteme ait E/R diyagramı Şekil 24’ te gösterilmektedir. Projede kullanılmak üzere veri tabanında üç adet tablo bulunmaktadır. Sistemi kullanacak doktorların bilgileri *doktor* tablosunda, hasta bilgileri *hasta* tablosunda ve hasta kayıtları *kayıt* tablosunda tutulmaktadır.



Şekil 28: E/R Diyagramı

C.5.3. Stored Procedures, Triggers, Kısıtların Tasarımı

Veri tabanımızda bulunan üç ana tablo Doktor, Hasta, ve Kayıt veri bütünlüğünü ve iş akışını düzenlemek için çeşitli kısıtlamalar içermektedir. Doktor tablosunda, TC sütunu hem PRIMARY KEY olarak tanımlanmış hem de benzersiz ve boş geçilemez olarak ayarlanmıştır, böylece her doktorun eşsiz bir kimliği olması sağlanmıştır. Ayrıca, uzmanlık_alanı ve iletişim_bilgisi gibi diğer önemli bilgiler de bu tabloda saklanmaktadır.

Hasta tablosunda, TC sütunu PRIMARY KEY olarak belirlenmiştir ve benzersizdir, bu da her hastanın tek bir kayda sahip olmasını garantiler. doğum_tarihi ve cinsiyet gibi demografik bilgiler bu tabloda tutulur.

Kayıt tablosu, doktor ve hasta arasındaki etkileşimleri kaydetmek için kullanılır ve kayıt_id sütunu PRIMARY KEY olarak tanımlanmıştır. Bu tablo ayrıca, doktor_tc ve hasta_tc sütunları üzerinden Doktor ve Hasta tablolarına FOREIGN KEY referansları içerir, bu sayede her kaydın hangi doktor ve hasta ile ilişkili olduğu belirlenir. tarih ve hastalık_derecesi gibi bilgilerle beraber, her muayenenin detayları bu tabloda saklanmaktadır.

C.6. Donanım Tasarımı

Sistemimizde donanım gerçekleşmesi bulunmamaktadır.

D.UYGULAMA

Uygulama bölümünde, tasarım sürecinde planlanan sistem, kullanıcı arayüzü, test, yazılım ve veri tabanı tasarımlarının uygulama sürecindeki gerçekleştirilme biçimi ele alınmıştır. Uygulama aşamasında, tasarlanan kullanıcı arayüzüne sadık kalınmış ve çeşitli iyileştirmeler uygulanmıştır. Bu iyileştirmeler, tasarım aşamasında belirlenen sistemin bütünlüğünü koruyacak şekilde yapılmıştır.

D.1 Geliştirilen Sistemin Sistem Tasarımlarını Karşılamanın Değerlendirilmesi

Oluşturulan proje, sistem gereksinimlerini sağlar şekilde tamamlanmıştır. Proje, sistem tasarımı olarak derin öğrenme modeli ve web uygulaması içermektedir. Projede kullanılan model %98 başarı oranıyla fotoğraf formatında gelen retina görüntüleri üzerinden kişiye ait hastalığın derecesini belirleyebilmektedir.

Geliştirilen web uygulaması bilgisayarlarda çalışabilir durumdadır. Web uygulamasının veri tabanı ve derin öğrenme modeliyle iletişimi Restful Api aracılığı ile gerçekleşmektedir. Web uygulaması, derin öğrenme modeli ve veri tabanı servisi ile sorunsun bir şekilde çalışmaktadır.

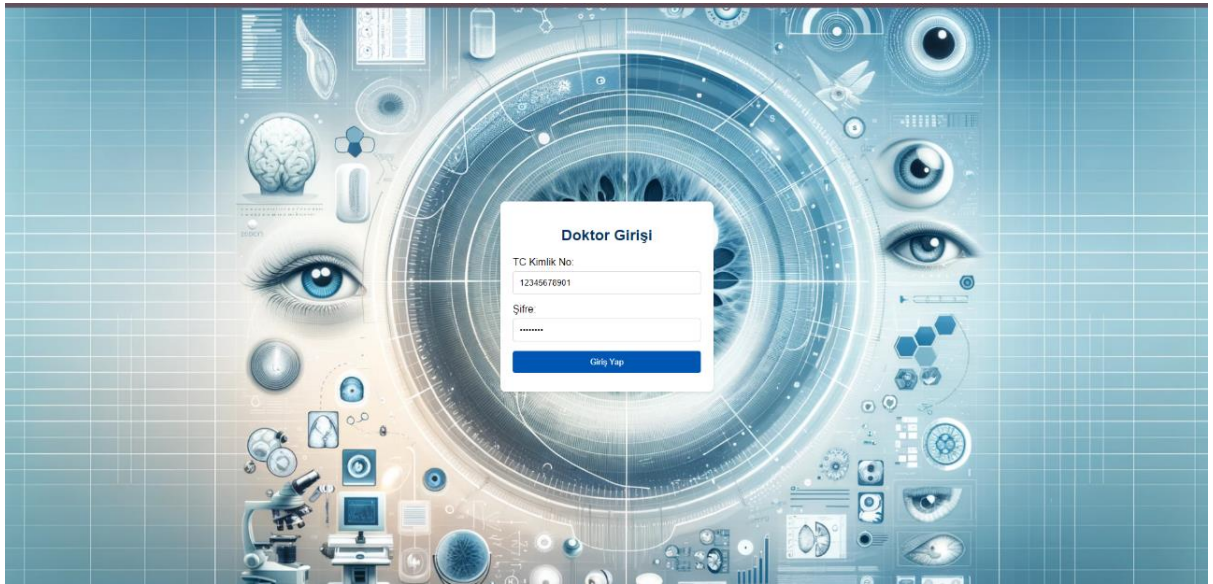
Derin öğrenme modellerini kullanmak ve veri tabanına erişim için Python kullanılmaktadır. İstemci kısmında ise HTML, CSS ve JavaScript teknolojileri kullanılmaktadır.

D.2. Kullanıcı ve Sistem Arayüzü Gerçeklemeleri

Kullanıcı arayüzü, projenin tasarım aşamasında planlandığı üzere, web tabanlı bir uygulama olarak geliştirilmiştir. Uygulama arayüzü geliştirilirken HTML, CSS ve Javascript teknolojileri kullanılmıştır. İstemci isteklerini karşılaması için oluşturulan sunucu Python 3.9.13 kullanılarak Flask Framework' ü ile çalışmaktadır.

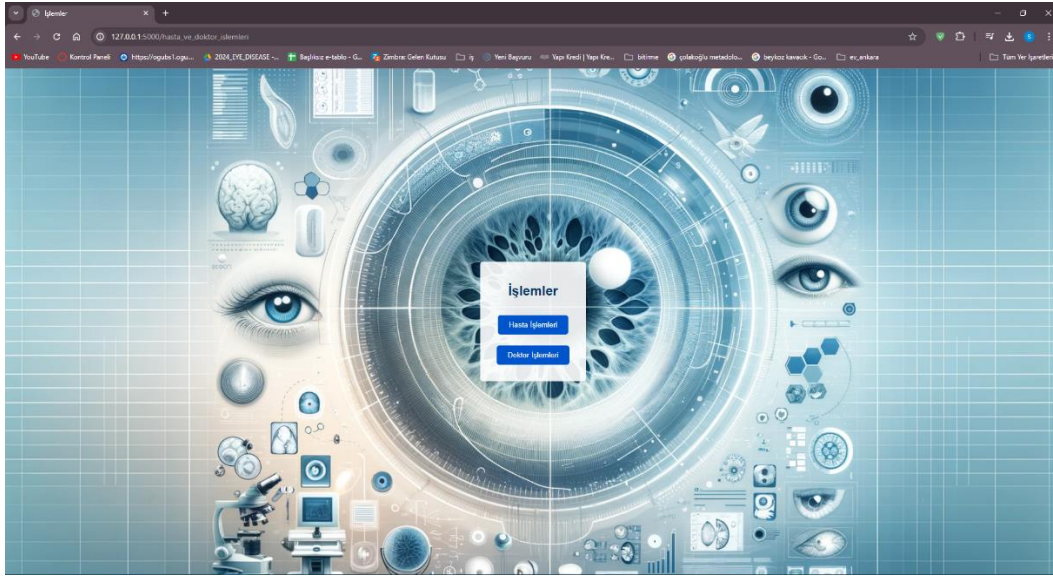
Kullanıcı arayüzü, projenin tasarım aşamasında planlandığı üzere, web tabanlı bir uygulama olarak geliştirilmiştir. Web uygulama arayüzü geliştirilirken HTML, CSS ve JavaScript teknolojileri kullanılmıştır. İstemci isteklerini karşılaması için oluşturulan sunucu Python 3.9.13 kullanılarak Flask Framework'ü ile çalışmaktadır. Web uygulamasının veri tabanı ile haberleşmesi Python Flask mysql.connector teknolojisi kullanılarak sağlandı. Veri tabanı servisi 3306 portunu kullanarak gelen http isteklerine yanıt verir.

Şekil 29'da web uygulamasına giriş ekranı görülmektedir. Hastane veri tabanında var olan doktorlar TC Kimlik numaraları ve şifre ile uygulamaya giriş yapabilirler. Doktorun giriş yetkisi yok ise diğer doktorlardan giriş bilgisi talep etmelidir.



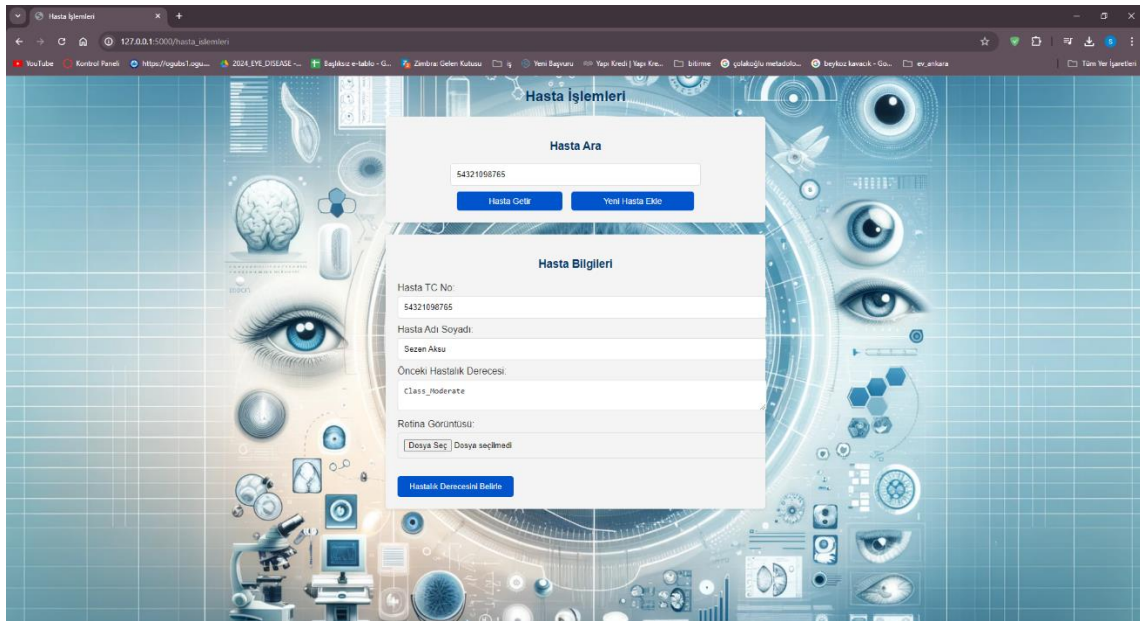
Şekil 29: Doktor Giriş Sayfası

Şekil 30’da işlemler sayfası gösterilmektedir. Doktorlar giriş yaptıklarında “hasta işlemleri” veya “doktor işlemleri” seçeneklerine tıklayarak ilgili ekrana yönlendirilirler.



Şekil 30: İşlemler Sayfası

Şekil 31’de hasta işlemleri ekranı gösterilmektedir. Doktorlar “hasta işlemleri” seçeneğini seçtikten sonra hastanın bilgilerini girecekleri ve teşhis sonucunu görebilecekleri ekrana yönlendirilirler.



Şekil 31: Hasta İşlemleri Sayfası

Şekil 32 ve Şekil 33’de retina görüntüsü yükleme ve teşhis sonucunu görme ekranı gösterilmektedir. “Hastalık Derecesini Belirle” butonuna tıklanarak teşhis ekranına yönlendirilir. “Dosya Seç” butonuna tıklanarak hastanın retina görüntüsü uygulamaya yüklenir ve ekranda gösterilir. “Hastalık Derecesini Belirle” butonuna tıklanarak görüntü modele gönderilir ve teşhis işlemi başlatılır. Model çalışması bittikten sonra teşhis ekrana yazdırılır ve teşhis sonucu ile görüntü veri tabanına ilgili tabloya yazılır.

Hasta İşlemleri

Hasta Ara

54321098765

[Hasta Getir](#) [Yeni Hasta Ekle](#)

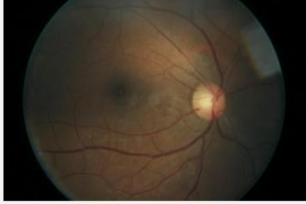
Hasta Bilgileri

Hasta TC No:
54321098765

Hasta Adı Soyadı:
Sezen Aksoy

Önceki Hastalık Derecesi:
Class_Moderate

Retina Görüntüsü:
[Dosya Seç](#) fundus03-3.jpg



[Hastalık Derecesini Belirle](#)

Şekil 32: Retina görüntüsü ekleme sayfası

Hastalık Derecesi

Class_Moderate

[Yeni Bir Analiz Yap](#)

Şekil 33: Teşhis sonucu sayfası

Şekil 34’de yeni hasta ekle ekranı gösterilmektedir. Doktorlar kaydetmek istedikleri hastanın bilgilerini girerler ve bilgiler veri tabanına kaydolur.

Yeni Hasta Ekle

Hasta TC No: 95175385201

Hasta Adı: Ahmet

Hasta Soyadı: Usta

Doğum Tarihi: 25.07.1986

Cinsiyet: Erkek

İletişim Bilgisi: 5552228833

Kaydet

Şekil 34: Yeni Hasta Ekle Sayfası

Yeni Hasta Ekle

Hasta TC No: 95175385201

Hasta Adı: Ahmet

Hasta Soyadı: Usta

Başarılı

Hasta başarıyla eklendi

OK

Şekil 35: Yeni Hasta Ekle Başarılı Sayfası

Şekil 36’da doktor işlemleri ekranı gösterilmektedir. Doktorlar bilgilerini güncellemek için bu ekranı kullanırlar. Ayrıca veri tabanına yeni doktor eklemek için “yeni doktor ekle” butonuna tıklarlar ve şekil 37’deki yeni doktor ekle ekranına yönlendirilirler.

Doktor İşlemleri Sayfası

TC Kimlik No: 12345678901

Doktor Adı: Ahmet

Doktor Soyadı: Yılmaz

Şifre: *****

Şifreyi Yeniden Giriniz: *****

Uzmanlık Alanı: Göz Doktoru

İletişim Bilgisi: 05331234567

Doktor İşlemleri Gözetle

Yeni Doktor Ekle

Şekil 36: Doktor İşlemleri Sayfası

Yeni Doktor Ekle

TC Kimlik No: 78451289563

Doktor Adı: Karim

Doktor Soyadı: Ataç

Şifre: *****

Uzmanlık Alanı: Göz

Telefon Numarası: 5556669922

Kaydet

Şekil 37: Yeni Doktor Ekle Sayfası

127.0.0.1:5000 web sitesinin mesajı: Doktor başarıyla eklendi.

Yeni Doktor Ekle

TC Kimlik No: 78451289563

Doktor Adı: Karim

Doktor Soyadı: Ataç

Şifre: *****

Uzmanlık Alanı: Göz

Telefon Numarası: 5556669922

Kaydet

Şekil 37: Yeni Doktor Ekle Başarılı Sayfası

D.3.Gerçekleşen Testler

Bu başlık altında gerçekleştirilen fonksiyonel testler ve performans testleri açıklanacaktır.

D.3.1.Fonksiyonel Testler

Proje kapsamında fonksiyonel test olarak birim ve entegrasyon testleri gerçekleştirilmiştir. Bu testlerin daha detaylı açıklamaları alt başlıklar altında verilmiştir.

D.3.1.1. Birim (Unit) Testi


Proje kapsamında derin öğrenme modelinin retina görüntüleri üzerinden hastalık derecesi belirlemesi, doktorların sisteme giriş yapması,yeni doktor eklenmesi, hasta bilgilerinin görüntülenmesi, yeni hasta eklenmesi, gibi endpointlerin ele alındığı fonksiyonların işlevleri ve gerçekleştirilecek durumların her birine birim test uygulanmıştır. Uygulamaya giriş yapılması işlemne birim test uygulandığında doktorun TC kimlik umarası ve şifresiyle uygulamaya giriş yapabilmesi beklenmektedir. Şekil 38’ de doktorun bilgilerini girerek sistemi giriş yapmaya çalıştığı görülmektedir. Şekil 39 ve 40’ ta doktorun girdiği bilgilere göre yönlendirildiği sayfalar gösterilemektedir.



Şekil 48: Birim Test - Giriş Sayfası



Şekil 39: Birim Test - Doğru Giriş



Şekil 5: Birim Test - Yanlış Giriş

D.3.1.2. Entegrasyon Testi

Entegrasyon testinde, web uygulamasının derin öğrenme modeli ile iletişimi test edilmiştir. Web uygulamasının derin öğrenme modeli ile iletişiminin test edilmesi işlemi, hastalık derecesini belirleme sayfasında uygulanmıştır. Test sonucunda, derin öğrenme modeline verilen retina görüntüsünün derecesinin, web sayfasında gösterilmesi beklenmiştir. Şekil 41 ve 42’deki görsellerde görsel ekleme ve sonuç alma sayfaları gösterilmektedir. Doktor, Şekil 41’de görülen hasta bilgileri altında bulunan “Dosya Seç” butonuna tıklayarak retina görüntüsü seçilmekte, seçilen retina görüntüsü ekrana yansıtılmaktadır. “Hastalık Derecesini Belirle” butonu ile yüklenen retina görüntüsünden elde edilen hastalık derecesi Şekil 42’deki ekranda gösterilmektedir.

Şekil 41: Entegrasyon Testi - Görüntü Yükleme

Şekil 42: Entegrasyon Testi - Sonuç Ekranı

D.3.2. Performans Testi

Derin öğrenme modelinin retina görüntüsünü sınıflandırması ve post isteğini yanıtlaması yaklaşık 2 ile 10 saniye arasında sürmektedir. Modelin bir retina görüntüsünü sınıflandırarak isteği yanıtlatma süresi oldukça idealdir. Kullanıcıların internet hızları, http bağlantılarının süresini etkileyeceğinden asıl önemli nokta kullanıcıların internet hızıdır.

Proje geliştirme aşamasında, derin öğrenme modeli lokal bilgisayarlarda çalıştırılmıştır ve model az sayıda post isteğini yanıtlamıştır. Gerçekleştirilen bu aşamalarda herhangi bir sorun ile karşılaşılmamıştır. Sistem içerisinde doktorun aynı anda birkaç hastayı görüntülemesi üzerine herhangi bir işlem bulunmadığı için sisteme ağır gelecek bir işlem gerçekleşmemektedir. Proje çok sayıda kullanıcı tarafından kullanıldığında çok sayıda isteğe yanıt veren sunucular kullanılmalıdır.

D.4. Yazılım/Veri Tabanı/Donanım Gerçeklemeleri

D.4.1. Yazılım Gerçeklemeleri

Projemizde derin öğrenme modeli, veri tabanı servisi ve web uygulaması olmak üzere üç adet yazılım modülü bulunmaktadır.

D.4.1.1. Diyabetik Retinopati Derecelendirme Modeli Gerçeklemeleri

Bulut tabanlı, kullanımı kolay ve ortak çalışmaya dayalı Google Colaboratory programlama ortamında ve Visual Studio Code kullanılarak modelin eğitimi, doğrulanması ve test işlemleri gerçekleştirilmiştir. Ayrıca Derin öğrenme uygulamaları için geliştirilmiş ve açık kaynaklı kütüphanelerden olan Pytorch yapısı kullanılmıştır. Derin öğrenme modeli Python programlama dili ile eğitildikten sonra bir sunucuda çalıştırılarak web uygulamasında kullanılmıştır. Kullanılan veri seti içerisinde 5 farklı diyabetik retinopati hastalık derecesine ait toplam 3664 adet fundus görüntüsü bulunmaktadır.

Proje kapsamında doktor rolüne fundus görsellerini değerlendirmesi için hastalık bulunmayan, hafif şiddetli, orta şiddetli, şiddetli ve proliferatif retina görüntüleri olmak üzere beş etiketli bir sınıflandırma modeli sunulmuştur. Şekil 1’de sınıflara ait görseller bulunmaktadır. EfficientNetV2b0 ve EfficientNetV2S modelleri kullanılarak eğitim yapılmıştır.

Model eğitimi için anlamsız bilgileri ortadan kaldırıp, anlamlı bilgileri belirginleştirmek amacıyla görüntülere çeşitli ön işleme adımları uygulanmıştır. Ön işleme adımlarında OpenCV ve PIL kütüphaneleri kullanılarak görseller hazır hale getirilmiştir. Bu işlemlerde hedef, görsel odağının retina olmasını sağlamak ve modelin görseldeki siyah köşelerini öğrenmesini engellemektir.


Ön işleme adımlarının ardından görsellere Tablo 17’ de gösterilen veri artırma yöntemleri uygulanmıştır.

Teknik Numarası	Artırma Tekniği	Parametreler
1	Rotation	20°
2	Horizontal Flip	True
3	Height Shift	0.2
4	Width Sift	0.2
5	Shear Range	0.2
6	Zoom Range	0.2
7	Fill Mode	‘nearest’

Tablo 17: Veri Artırma Metotları ve Parametreleri

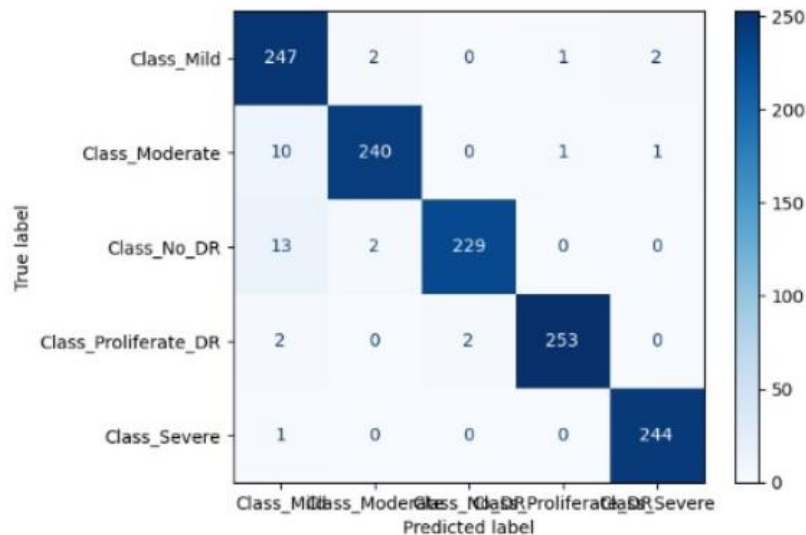
EfficientNetV2B0 modeli önceden eğitilmiş olarak yüklenmiştir. Modelin çıktısı üzerine sırasıyla Global Average Pooling, Batch Normalization, iki katmanlı Dense ve Dropout katmanları eklenmiştir. İlk Dense katmanında 1024 nöron ve aktivasyon fonksiyonu olarak "relu" kullanılmış, ikinci Dense katmanında ise 512 nöron yer almaktadır ve yine "relu" aktivasyon fonksiyonu kullanılmaktadır. Çıktı katmanında ise 5 sınıf için "softmax" aktivasyon fonksiyonu kullanılmıştır. Model, "categorical cross entropy" kayıp fonksiyonu ve 0.001 öğrenme oranına sahip Adam optimizasyon algoritması ile derlenmiştir. Eğitim tur sayısı (epoch değeri) 50, tek bir grupta bulunacak eğitim örneklerinin toplam sayısı ise (batch-size değeri) 32 olarak belirlenmiştir. Eğitim sürecini optimize etmek için ReduceLROnPlateau ve EarlyStopping gibi callback'ler yapılandırılmıştır. ReduceLROnPlateau, eğitim sırasında modelin doğrulama kaybı üzerinde bir iyileşme olmaması durumunda öğrenme oranını azaltırken, EarlyStopping, belirli bir süre boyunca doğrulama kaybında iyileşme olmaması durumunda eğitimi durdurmakta ve en iyi ağırlıkları geri yüklemektedir.

Model eğitiminde, eğitim verisinin % 30' u doğrulama veri seti olarak kullanılmıştır. Model başarısının ve kaybının eğitim turu bazında değişimine ait grafikler aşağıdaki Şekil 43' te gösterilmektedir.



Şekil 43: Model Başarı ve Kayıp Grafikleri

Test verileri üzerinden, model performansını değerlendirmek için karışıklık matrisi çıkartılmıştır. Elde edilen karışıklık matrisi ve matrise ait değerler Şekil 44 ve 45' te gösterilmektedir.



Şekil 44: Karışıklık Matrisi

	precision	recall	f1-score	support
Class_Mild	0.90	0.98	0.94	252
Class_Moderate	0.98	0.95	0.97	252
Class_No_DR	0.99	0.94	0.96	244
Class_Proliferate_DR	0.99	0.98	0.99	257
Class_Severe	0.99	1.00	0.99	245
accuracy			0.97	1250
macro avg	0.97	0.97	0.97	1250
weighted avg	0.97	0.97	0.97	1250

Şekil 45: Karışıklık Matrisi Değerlendirmesi

D.4.1.2 Web Uygulaması Gerçeklemesi

Web uygulaması ön yüz ve arka yüz olmak üzere iki kısımdan oluşmaktadır. Ön yüz geliştirilirken HTML, CSS ve JavaScript teknolojileri kullanılmıştır. Ön yüz kullanıcı dostu ve öğretme gerekliliği olmadan kullanabilecek kolaylıkta tasarlanmıştır.

Arka yüz, daha efektif ve genişletilebilir olması nedeniyle Python Flask Framework teknolojisi kullanılarak geliştirilmiştir. Veri tabanı ile arka yüz arasındaki iletişim için mysql.connector teknolojisi ile gerçekleştirilmiştir. Bu sayede Sql sorguları yazmaya gerek olmadan veri tabanında işlemler yapılabilmiştir.

D.4.2. Veri Tabanı Gerçeklemeleri

Projemiz bir web uygulamasıdır ve kullanılacak verilerin tamamı yerel bir veri tabanında tutulmaktadır. Veri tabanı MySQL kullanılarak oluşturulmuştur. Bu veri tabanı tasarım aşamasında planlanan veri tabanı tasarımına bağlı kalınarak oluşturulmuştur. Web uygulamasının veritabanı ile iletişimi, Flask framework'ü kullanılarak oluşturulan servisler aracılığıyla sağlanmaktadır.

D.4.3. Donanım Gerçeklemeleri

Sistemimizde donanım gerçekleştirilmesi bulunmamaktadır.

E. SONUÇ VE ÖNERİLER

Oluşturulan proje sistem gereksinimlerini sağlar şekilde tamamlanmıştır ve sürdürülebilir bir ürün olarak kullanılabilir şekilde dizayn edilmiştir. Sağlık sektörü kapsamında, göz doktorlarının kullanılabileceği şekilde bir web uygulaması geliştirilmiştir. Uygulama, doktorlara teşhis aşamasında yardımcı olacak, maliyeti düşük, daha hızlı ve daha doğru sonuçlar elde edebileceği bir altyapı sunmaktadır. Uygulamada, hastane veri tabanında kayıtlı olan doktorlar giriş yaptıklarında TC kimlik numarasını sorguladıkları hastanın, hastane veri tabanında kayıtlı bilgilerini görebilecekleri bir sayfaya yönlendirilirler. Hastanın retina görüntüsünü teşhis etmek isteyen doktor “Hastalık Derecesini Belirle” butonuyla teşhis sayfasına yönlendirilir. Doktor, retina görüntüsünü sayfaya yükler ve modeli çalıştırır. Geliştirilen derin öğrenme modeli gelen retina görüntüsünü hastalık bulunmayan, hafif şiddetli, orta şiddetli, şiddetli ve proliferatif olmak üzere 5 sınıf için % 97 başarı oranıyla sınıflandırabilmektedir. Geliştirilen model, EfficientNetV2S kullanılarak eğitilmiştir. Modelin daha hızlı eğitilebilmesi için EfficientnetV2B0 modeli de denenmiştir.

ancak EfficientNetV2S modeli ile alınan başarı oranı daha yüksek olduğundan dolayı uygulamada EfficientNetV2S kullanılmıştır.

Görseller üzerinde yapılan gereksiz ön işleme adımları, görsellerde veri kaybına sebebiyet vermektedir. Veri kaybı başarı oranını büyük oranda etkilemektedir. Model geliştirme aşamasında fazla ön işleme adımı sebebiyle veri kaybı yaşanmış ve model ezbere düşmüştür. Bu sebeple görseller, üzerlerinde çok fazla değişiklik gerçekleştirilmeden kullanılmıştır ve model performansında artış gözlemlenmiştir.

Geliştirilen derin öğrenme modeli 5 farklı diyabetik retinopati derecesi için sınıflandırma yapabilmektedir. Daha fazla sınıf için sınıflandırma yapılmak istendiğinde veri seti güncellenerek model yeniden eğitilebilir. İlerleyen çalışmalarda derin öğrenme modeli için veri seti arttırılabilir ve modelin cevap verme süresinin kısaltılması için çalışmalar yapılabilir.

F. REFERANSLAR

- [1]“Diabetic Retinopathy Detection”, Internet: <https://www.kaggle.com/c/diabetic-retinopathy-detection/data>, 17 Şubat, 2015
- [2] Pak, A., Ziyaden, A., Tukeshev, K., Jaxylykova, A., & Abdullina, D. (2020). Comparative analysis of deep learning methods of detection of diabetic retinopathy. *Cogent Engineering*, 7(1), 1805144.
- [3] Jiang, H., Yang, K., Gao, M., Zhang, D., Ma, H., & Qian, W. (2019, July). An interpretable ensemble deep learning model for diabetic retinopathy disease classification. In *2019 41st annual international conference of the IEEE engineering in medicine and biology society (EMBC)* (pp. 2045-2048). IEEE.
- [4] Saini, M., & Susan, S. (2022). Diabetic retinopathy screening using deep learning for multi-class imbalanced datasets. *Computers in Biology and Medicine*, 149, 105989.
- [5] Qummar, S., Khan, F. G., Shah, S., Khan, A., Shamshirband, S., Rehman, Z. U., ... & Jadoon, W. (2019). A deep learning ensemble approach for diabetic retinopathy detection. *Ieee Access*, 7, 150530-150539.
- [6] Geetha, S., Parashar, M., Abhishek, J. S., Turaga, R. V., Lawal, I. A., & Kadry, S. (2022). Diabetic Retinopathy Grading with Deep Visual Attention Network. *International Journal of Online & Biomedical Engineering*, 18(9).
- [7] Kaya, E., & Saritas, I. (2022, June). Performances of cnn architectures on diabetic retinopathy detection using transfer learning. In *2022 57th International Scientific Conference on Information, Communication and Energy Systems and Technologies (ICEST)* (pp. 1-4). IEEE.
- [8] Rajkumar, R. S., Jagathishkumar, T., Ragul, D., & Selvarani, A. G. (2021, January). Transfer learning approach for diabetic retinopathy detection using residual network. In *2021 6th international conference on inventive computation technologies (ICICT)* (pp. 1189-1193). IEEE.
- [9] Farooq, M. S., Arooj, A., Alroobaea, R., Baqasah, A. M., Jabarulla, M. Y., Singh, D., & Sardar, R. (2022). Untangling computer-aided diagnostic system for screening diabetic retinopathy based on deep learning techniques. *Sensors*, 22(5), 1803.
- [10] Nawaz, F., Ramzan, M., Mehmood, K., Khan, H. U., Khan, S. H., & Bhutta, M. R. (2021). Early Detection of Diabetic Retinopathy Using Machine Intelligence through Deep Transfer and Representational Learning. *Computers, Materials & Continua*, 66(3).
- [11] Nurrahmadayeni, N., Efendi, S., & Zarlis, M. (2022). Analysis of deep learning methods in diabetic retinopathy disease identification based on retinal fundus image. *International Journal of Nonlinear Analysis and Applications*, 13(1), 1639-1647.
- [12] Nazir, T., Irtaza, A., Javed, A., Malik, H., Hussain, D., & Naqvi, R. A. (2020). Retinal image analysis for diabetes-based eye disease detection using deep learning. *Applied Sciences*, 10(18), 6185.
- [13] Hathwar, S. B., & Srinivasa, G. (2019, September). Automated grading of diabetic retinopathy in retinal fundus images using deep learning. In *2019 IEEE International Conference on Signal and Image Processing Applications (ICSIPA)* (pp. 73-77). IEEE.
- [14] YALÇIN, N., ALVER, S., & ULUHATUN, N. Diyabetik Retinopati Hastalığının Erken Tespiti İçin Derin Öğrenme İle Retina Görüntülerinin Sınıflandırılması Classification of Retinal Images with Deep Learning for Early Detection of Diabetic Retinopathy Disease.

- [15] Nagaraj, G., Simha, S. C., Chandra, H. G., & Indiramma, M. (2019, March). Deep Learning Framework for Diabetic Retinopathy Diagnosis. In *2019 3rd International Conference on Computing Methodologies and Communication (ICCMC)* (pp. 648-653). IEEE.
- [16] Khan, Z., Khan, F. G., Khan, A., Rehman, Z. U., Shah, S., Qummar, S., ... & Pack, S. (2021). Diabetic retinopathy detection using VGG-NIN a deep learning architecture. *IEEE Access*, 9, 61408-61416.
- [17] Mondal, S. S., Mandal, N., Singh, K. K., Singh, A., & Izonin, I. (2022). Edldr: An ensemble deep learning technique for detection and classification of diabetic retinopathy. *Diagnostics*, 13(1), 124.
- [18] Shankar, K., Sait, A. R. W., Gupta, D., Lakshmanaprabu, S. K., Khanna, A., & Pandey, H. M. (2020). Automated detection and classification of fundus diabetic retinopathy images using synergic deep learning model. *Pattern Recognition Letters*, 133, 210-216.
- [19] de La Torre, J., Valls, A., & Puig, D. (2020). A deep learning interpretable classifier for diabetic retinopathy disease grading. *Neurocomputing*, 396, 465-476.
- [20] Gürcan, Ö. F., ATICI, U., & BEYCA, Ö. F. (2023). A hybrid deep learning-metaheuristic model for diagnosis of diabetic retinopathy. *Gazi University Journal of Science*, 36(2), 693-703.
- [21] Taranum, M. P. L., & Rajashekar, J. S. (2022). Image Based Edge Weighted Linked Segmentation Model Using Deep Learning for Detection of Diabetic Retinopathy. *Traitement du Signal*, 39(1).
- [22] Zhang, Q. M., Luo, J., & Cengiz, K. (2021). An optimized deep learning-based technique for grading and extraction of diabetic retinopathy severities. *Informatica*, 45(5).
- [23] Seth, S., & Agarwal, B. (2018). A hybrid deep learning model for detecting diabetic retinopathy. *Journal of Statistics and Management Systems*, 21(4), 569-574.
- [24] Seth, S., & Agarwal, B. (2018). A hybrid deep learning model for detecting diabetic retinopathy. *Journal of Statistics and Management Systems*, 21(4), 569-574.
- [25] Ai, Z., Huang, X., Fan, Y., Feng, J., Zeng, F., & Lu, Y. (2021). DR-IIXRN: detection algorithm of diabetic retinopathy based on deep ensemble learning and attention mechanism. *Frontiers in Neuroinformatics*, 15, 778552.
- [26] Tan, Z., Simkin, S., Lai, C., & Dai, S. (2019). Deep learning algorithm for automated diagnosis of retinopathy of prematurity plus disease. *Translational vision science & technology*, 8(6), 23-23.
- [27] Islam, K. T., Wijewickrema, S., & O'Leary, S. (2019, June). Identifying diabetic retinopathy from oct images using deep transfer learning with artificial neural networks. In *2019 IEEE 32nd international symposium on computer-based medical systems (CBMS)* (pp. 281-286). IEEE.
- [28] Umamageswari, A., Duela, J. S., & Raja, K. (2021, December). Identifying Diabetics Retinopathy using Deep Learning based Classification. In *2021 22nd International Arab Conference on Information Technology (ACIT)* (pp. 1-6). IEEE.
- [29] Fayyaz, A. M., Sharif, M. I., Azam, S., Karim, A., & El-Den, J. (2023). Analysis of diabetic retinopathy (DR) based on the deep learning. *Information*, 14(1), 30.
- [30] Alfian, G., Syafrudin, M., Fitriyani, N. L., Anshari, M., Stasa, P., Svub, J., & Rhee, J. (2020). Deep neural network for predicting diabetic retinopathy from risk factors. *Mathematics*, 8(9), 1620.

- [31] Harshitha, C., Asha, A., Pushkala, J. L. S., Anogini, R. N. S., & Karthikeyan, C. (2021, January). Predicting the stages of diabetic retinopathy using deep learning. In *2021 6th international conference on inventive computation technologies (ICICT)* (pp. 1-6). IEEE.
- [32] Oulhadj, M., Riffi, J., Chaimae, K., Mahraz, A. M., Ahmed, B., Yahyaouy, A., ... & Tairi, H. (2022). Diabetic retinopathy prediction based on deep learning and deformable registration. *Multimedia Tools and Applications*, 81(20), 28709-28727.
- [33] Chaurasia, B. K., Raj, H., Rathour, S. S., & Singh, P. B. (2023). Transfer learning–driven ensemble model for detection of diabetic retinopathy disease. *Medical & Biological Engineering & Computing*, 61(8), 2033-2049.

E. DEĞERLENDİRME ŞABLONU

		Değ.	Puan	Not
PLANLAM A(25)	A.1. Özet(Abstract) ve Anahtar Kelimeler(Keywords)		2	
	A.2. Bilgi Gereksinim Belirleme, Problemin Tanımlanması	A.2 için kısa yöntem bilgisi	2	
		A.2.1.Amaç	2	
		A.2.2 Konu ve Kapsam	2	
		A.2.3 Litaratür Özeti	3	
	A.3. Beklenen Fayda	A.3.1.Özgün Değer	3	
		A.3.2 Yaygın Etki / Katma Değer	2	
	A.4.Yöntem		3	
	A.5. Araştırma Olanakları		1	
	A.6. Çalışma Takvimi	A.6.1. İş zaman Çizelgesi	3	
		A.6.2. Kim ne iş yapacak	2	
	Not: Tübitak vb proje geçmiş ise PLANLAMA'dan belirtmek kaydı ile tam puan(25) alınır.			
ANALİZ(25)	B.1. Sistem Gereksinimlerini Ortaya Çıkarma Yöntem ve Teknikleri		3	
	B.2. Sistem Gereksinimler	B.2.1.İşlevsel Gereksinimler:	6	
		B.2.2.Sistem ve Kullanıcı Ara yüzleri ile ilgili Gereksinimler:	5	
		B.2.3.Veriyle İlgili Gereksinimler:	5	
		B.2.4.Kullanıcılar ve İnsan Faktörü Gereksinimleri, Güvenlik Gereksinimleri:	3	
		B.2.5.Teknik ve Kaynak Gereksinimleri, Fiziksel Gereksinimler:	3	
	** Belirlenen sistem gereksinimleri tasarımda kullanılacak kadar detaylı değilse -10 puan alınır.		-10	
TASARIM(40)	C.1. Sistem Tasarımı		3	
	C.2.Kullanıcı ve Sistem Ara yüzü Tasarımları		7	

	C.3.Test Tasarımı	C.3.1. Gereksinim analizlerinden teste yönelik hedeflerinin detaylandırılması		5	
		C.3.2. Fonksiyonel Test Tasarımı		5	
		C.3.3. Performans Test Tasarımı		5	
		Not: Bu başlık altında tasarım yoksa veya yeterli değilse -10 puan alınır		-10	
	TAKİP EDEN KISIMLARIN(C4-C6) olması gerekiyorsa ORTALAMASI ALINIR.			15	
	C.4.Yazılım Tasarımı	C.4.1.Gereksinime Bağlı Tasarım Kalıp(lar)ı Seçimi		6	
		C.4.2.UML Kullanarak Tasarım Diyagramları Oluşturma		9	
	C.5.Verİ Tabanı Tasarımı	C.5.1.Verİ Tabanı İsterler Dokümanı		5	
		C.5.2.E/R Diyagramı		5	
		C.5.3. Stored Procedures, Triggers, Kısıtların tasarımı		5	
	C.6. Donanım Tasarımı	C.6.1. Sistem Mekanik Bileşen Tasarımlarının Verilmesi		5	
		C.6.2. Elektronik Tasarım		5	
		C.6.3. Gömülü Yazılım Tasarımları		5	
SUNUM(10)		Görsel Materyal		5	
		Zamanı Etkin Kullanma		5	
TOPLAM				100	